

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ



ĐỒ ÁN TỐT NGHIỆP
XÂY DỰNG HỆ THỐNG QUẢN LÝ VƯỜN CÂY VÀ
HỖ TRỢ DỰ ĐOÁN MỘT SỐ BỆNH TRÊN CÂY CÓ MÚI

Giảng viên hướng dẫn: **ThS. PHẠM MINH ĐƯƠNG**

Sinh viên thực hiện: **NGUYỄN PHÚC AN**

Mã số sinh viên: **110122214**

Lớp: **DA22TTA**

Khoá: **2022**

Vĩnh Long, tháng 6 năm 2026

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ



ĐỒ ÁN TỐT NGHIỆP
XÂY DỰNG HỆ THỐNG QUẢN LÝ VƯỜN CÂY VÀ
HỖ TRỢ DỰ ĐOÁN MỘT SỐ BỆNH TRÊN CÂY CÓ MÚI

Giảng viên hướng dẫn: **ThS. PHẠM MINH ĐƯƠNG**

Sinh viên thực hiện: **NGUYỄN PHÚC AN**

Mã số sinh viên: **110122214**

Lớp: **DA22TTA**

Khoá: **2022**

Vĩnh Long, tháng 6 năm 2026

MỤC LỤC

LỜI MỞ ĐẦU	i
LỜI CẢM ƠN	ii
BẢN NHẬN XÉT ĐỒ ÁN TỐT NGHIỆP.....	iii
DANH MỤC CÁC BẢNG.....	vii
DANH MỤC HÌNH ẢNH	viii
KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT	x
CHƯƠNG 1: ĐẶT VẤN ĐỀ.....	1
1.1. Lý do chọn đề tài.....	1
1.2. Mục tiêu nghiên cứu	1
1.3. Nội dung nghiên cứu.....	2
1.4. Đối tượng và phạm vi nghiên cứu	3
1.4.1. Đối tượng nghiên cứu	3
1.4.2. Phạm vi nghiên cứu	3
1.5. Phương pháp nghiên cứu	4
1.5.1. Phương pháp nghiên cứu lý thuyết	4
1.5.2. Phương pháp nghiên cứu khảo sát.....	4
1.5.3. Phương pháp nghiên cứu thực nghiệm	4
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	6
2.1. Tổng quan về hệ thống thông tin và ứng dụng web	6
2.1.1. Tìm hiểu về kiến trúc Client-Server	6
2.1.2. Nguyên lý hoạt động của kiến trúc Client-Server	6
2.1.3. Tổng quan về RESTful API.....	7
2.1.4. Các phương thức và thành phần cốt lõi của RESTful API.....	7
2.2. Tổng quan về Node.js và ExpressJS	8

2.3.	Tổng quan về React	8
2.4.	Tổng quan về MongoDB	9
2.5.	Tổng quan về Machine Learning	9
2.6.	Tổng quan về Computer Vision trong nông nghiệp	10
2.7.	Mô hình MobileNetV2	11
2.8.	Kỹ thuật Transfer Learning trong nhận dạng ảnh	12
2.9.	Kỹ thuật Grad-CAM và Explainable AI	13
2.10.	Các phương pháp đánh giá mô hình	13
2.9.1.	Ma trận nhầm lẫn (Confusion Matrix)	13
2.9.2.	Độ chính xác tổng quan (Accuracy)	14
2.9.3.	Độ chính xác của dự đoán (Precision)	15
2.9.4.	Độ nhạy / Tỷ lệ thu hồi (Recall)	15
2.9.5.	Điểm F1-Score (F-measure)	16
2.9.6.	Hàm mất mát Entropy chéo đa lớp (Categorical Cross-Entropy Loss)	16
2.11.	Một số bệnh trên cây có múi	17
2.12.	Các công trình nghiên cứu liên quan	18
CHƯƠNG 3: HIỆN THỰC HÓA NGHIÊN CỨU		22
3.1.	Mô tả hệ thống	22
3.2.	Các chức năng của hệ thống	23
3.3.	Kiến trúc hệ thống	24
3.4.	Thiết kế dữ liệu	25
3.5.	Thiết kế xử lý	30
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU		33
4.1.	Giao diện và chức năng hệ thống	33
4.1.1.	Tổng quan giao diện	33

4.1.2.	Chức năng xác thực	35
4.1.3.	Quản lý vườn	35
4.1.4.	Quản lý chi phí.....	37
4.1.5.	Quản lý nhật ký.....	38
4.1.6.	Dự đoán bệnh.....	38
4.1.7.	Thư viện bệnh	40
4.1.8.	Một số chức năng quản trị	41
4.1.8.1.	Xem tổng quan hệ thống	41
4.1.8.2.	Chức năng quản lý bệnh.....	42
4.1.8.3.	Chức năng quản lý nhật ký bệnh.....	42
4.1.8.4.	Chức năng quản lý nhật ký canh tác	43
4.1.8.5.	Chức năng quản lý chi phí	44
4.1.8.6.	Chức năng quản lý thông báo và kiểm soát hoạt động	45
4.1.8.7.	Chức năng quản lý phân bón và thuốc	46
4.1.8.8.	Chức năng đào tạo lại ML và bậc bảo trì hệ thống.....	47
4.2.	Kết quả huấn luyện mô hình.....	49
4.2.1.	Mô tả dữ liệu huấn luyện	49
4.2.2.	Cấu hình huấn luyện	49
4.2.3.	Kết quả huấn luyện	51
4.2.4.	Đánh giá mô hình.....	52
4.3.	Demo kết quả Grad-CAM.....	53
4.4.	Đánh giá hệ thống	54
4.5.	Thảo luận	56
4.5.1.	Cơ chế tái huấn luyện (Retraining) từ dữ liệu người dùng đóng góp.....	56
4.5.2.	Tích hợp đa tiêu chí lâm sàng hỗ trợ dự đoán	57

4.5.3.	Khai phá nhật ký bệnh trạng để dự báo theo dòng thời gian.....	57
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....		59
5.1.	Kết luận.....	59
5.2.	Hướng phát triển	60
PHỤ LỤC		61
DANH MỤC TÀI LIỆU THAM KHẢO		64

LỜI MỞ ĐẦU

Trong bối cảnh chuyển đổi số đang diễn ra mạnh mẽ trên nhiều lĩnh vực, nông nghiệp cũng không nằm ngoài xu thế đó. Việc ứng dụng công nghệ thông tin vào quản lý và sản xuất nông nghiệp không chỉ giúp nâng cao năng suất mà còn góp phần giảm thiểu rủi ro, tối ưu hóa chi phí và nâng cao chất lượng sản phẩm. Đặc biệt, đối với cây có múi nói chung và cây cam nói riêng, một trong những loại cây trồng chủ lực tại Việt Nam, việc quản lý vườn cây và phát hiện sớm các loại bệnh là yếu tố then chốt quyết định hiệu quả kinh tế.

Tuy nhiên, thực tế cho thấy việc quản lý vườn cây hiện nay tại nhiều địa phương vẫn còn mang tính thủ công, thiếu sự hỗ trợ của các hệ thống thông minh. Đồng thời, việc nhận diện và dự đoán bệnh trên cây chủ yếu dựa vào kinh nghiệm của người nông dân, dễ dẫn đến sai sót và chậm trễ trong xử lý.

Xuất phát từ những yêu cầu thực tiễn đó, đề tài *“Xây dựng hệ thống quản lý vườn cây và hỗ trợ dự đoán một số bệnh trên cây có múi”* được thực hiện nhằm nghiên cứu, thiết kế và phát triển một hệ thống hỗ trợ quản lý thông tin vườn cây một cách hiệu quả, nhận diện bệnh thông qua hình ảnh bằng mô hình trí tuệ nhân tạo. Hệ thống hướng đến việc hỗ trợ người dùng theo dõi tình trạng cây trồng, đưa ra cảnh báo sớm và góp phần nâng cao hiệu quả sản xuất nông nghiệp.

Trong khuôn khổ khóa luận, nội dung nghiên cứu tập trung vào việc khảo sát thực trạng, phân tích yêu cầu hệ thống, thiết kế mô hình và xây dựng ứng dụng, từ đó đánh giá hiệu quả và khả năng ứng dụng trong thực tế.

LỜI CẢM ƠN

Trong suốt quá trình thực hiện khóa luận tốt nghiệp với đề tài “Xây dựng hệ thống quản lý vườn cây và hỗ trợ dự đoán một số bệnh trên cây có múi”, tôi đã nhận được sự giúp đỡ, hướng dẫn và động viên quý báu từ nhiều cá nhân và tập thể.

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc đến quý thầy/cô trong Khoa Công nghệ Thông tin, Trường Kỹ thuật và Công nghệ, Đại học Trà Vinh những người đã tận tình giảng dạy và truyền đạt kiến thức nền tảng trong suốt quá trình học tập.

Đặc biệt, tôi xin chân thành cảm ơn thầy Phạm Minh Dương, người đã trực tiếp hướng dẫn, định hướng và hỗ trợ tôi trong suốt quá trình thực hiện đề tài. Những góp ý chuyên môn và sự tận tâm của thầy là yếu tố quan trọng giúp em hoàn thành khóa luận này.

Tôi cũng xin gửi lời cảm ơn đến gia đình và bạn bè đã luôn bên cạnh, động viên và tạo điều kiện thuận lợi để tôi có thể tập trung học tập và hoàn thành tốt nhiệm vụ của mình.

Mặc dù đã cố gắng hết sức, nhưng do hạn chế về kiến thức và thời gian, khóa luận không tránh khỏi những thiếu sót. Tôi rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy/cô để đề tài được hoàn thiện hơn.

Tôi xin chân thành cảm ơn!

Vĩnh Long, ngày ... tháng ... năm 2026

Sinh viên thực hiện

Nguyễn Phúc An

BẢN NHẬN XÉT ĐỒ ÁN TỐT NGHIỆP

(Của giảng viên hướng dẫn)

Họ và tên sinh viên: Nguyễn Phúc An

MSSV: 110122214

Ngành: Công nghệ Thông Tin

Khóa: 2022

Tên đề tài: Xây dựng hệ thống quản lý vườn cây và hỗ trợ dự đoán một số bệnh trên cây có múi.

Họ và tên Giáo viên hướng dẫn: Phạm Minh Dương

Chức danh: Giảng viên

Học vị: Thạc sĩ

NHẬN XÉT

1. Nội dung đề tài:

Đề tài tập trung khảo sát thực tế và phân tích nghiệp vụ quản lý nông nghiệp (mùa vụ, chi phí, nhật ký canh tác) trong mô hình Hợp tác xã. Nghiên cứu về kiến trúc Client-Server, RESTful API và hệ sinh thái công nghệ web gồm ReactJS, Node.js, ExpressJS kết hợp cơ sở dữ liệu MongoDB. Nghiên cứu về trí tuệ nhân tạo, trọng tâm là kiến trúc mạng nơ-ron học sâu MobileNetV2, kỹ thuật học chuyển giao Transfer Learning, công cụ trực quan hóa bản đồ nhiệt Grad-CAM để chẩn đoán bệnh qua ảnh lá, quả của cây cam và tích hợp trợ lý ảo Gemini AI tư vấn. Xây dựng và thực nghiệm thành công một hệ thống ứng dụng web hoàn chỉnh, thực hiện tiền xử lý và huấn luyện mô hình với bộ dữ liệu gồm 13,202 ảnh thuộc 10 phân lớp trạng thái bệnh lý khác nhau.

2. Ưu điểm:

Đề tài mang tính toàn diện cao khi kết hợp chặt chẽ giữa quản lý nghiệp vụ nông nghiệp tập trung và phân hệ chẩn đoán dịch bệnh bằng công nghệ thị giác máy tính. Kiến trúc mạng MobileNetV2 là giải pháp tối ưu, giúp hệ thống đạt tốc độ xử lý nhanh, tiết kiệm tối đa tài nguyên tính toán và chi phí hạ tầng máy chủ, phù hợp cho nông dân thao tác trên thiết bị có cấu hình trung bình. Ứng dụng kỹ thuật giải thích mô hình Grad-CAM giúp trực quan hóa vùng đặc trưng mà AI chú ý, tăng tính minh bạch và độ tin cậy của kết quả chẩn đoán đối với nhà vườn. Giao diện hệ thống được thiết kế thân thiện, bố cục khoa học, đáp ứng tốt trải nghiệm của cả đối tượng nông dân và cán bộ quản lý. Kết quả thực nghiệm mô hình học máy rất ấn tượng, độ chính xác trên tập xác thực đạt khoảng 90.24% và 89.27% trên tập kiểm tra, cho thấy khả năng hội tụ và tổng quát hóa tốt. Phân quyền hệ thống rõ ràng, trang quản trị tích hợp nhiều tính năng như kiểm soát hoạt động vườn qua thông báo và cho phép tái huấn luyện mô hình trực tuyến.

3. Khuyết điểm:

Mô hình còn chịu sự chi phối và phụ thuộc lớn vào chất lượng hình ảnh đầu vào; các mẫu ảnh bị mờ, nhiễu hoặc thiếu sáng có thể làm sụt giảm độ chính xác. Nguồn dữ liệu huấn luyện dù lớn nhưng chưa bao quát được hết các biến thể tự nhiên ngoài thực địa và có sự phân bố chưa đồng đều, một số lớp bệnh hiếm còn khan hiếm mẫu vật. Hệ thống

chưa được tối ưu hóa hoàn toàn để hỗ trợ người dùng vận hành ở chế độ ngoại tuyến khi mất kết nối mạng Internet tại vườn. Thuật toán hiện tại chỉ dựa trên đặc trưng hình ảnh lâm sàng, chưa kết hợp các dữ liệu ngữ cảnh phi hình ảnh như thông số môi trường (nhiệt độ, độ ẩm) để tăng độ chính xác cho các ca bệnh phức tạp hoặc nhiễm trùng kép.

4. Điểm mới đề tài:

Điểm mới đột phá và là khoảng trống nghiên cứu lớn nhất được giải quyết. Không dừng lại ở một công cụ AI nhận diện bệnh độc lập, đề tài đã tích hợp thành công mô hình học sâu vào một nền tảng quản lý nông nghiệp tập trung mang tính liên kết ở cấp Hợp tác xã. Hệ thống cho phép số hóa, phân quyền thành viên, ghi nhật ký canh tác và lưu vết dịch bệnh theo từng mùa vụ của mỗi nông hộ. Áp dụng thành công Grad-CAM vào bài toán nông nghiệp thực tế tại Việt Nam, giúp thu hẹp khoảng cách niềm tin giữa người nông dân và công nghệ học sâu. Tích hợp thành công trợ lý ảo tư vấn thông qua API Gemini AI giúp tự động hóa việc đưa ra các phản hồi, lời khuyên và biện pháp xử lý bằng tiếng Việt một cách trực quan, kịp thời.

5. Giá trị thực trên đề tài:

Đề tài bám sát chiến lược chuyển đổi số và phát triển nông nghiệp thông minh, có ý nghĩa thực tiễn rất lớn đối với các vùng canh tác cây cam trọng điểm tại Việt Nam. Giúp các tổ chức nông nghiệp địa phương (Hợp tác xã) số hóa toàn diện quy trình tổ chức, vận hành, kiểm soát chi phí và theo dõi dòng lịch sử canh tác một cách khoa học. Là công cụ hỗ trợ chẩn đoán từ xa đặc lực, giúp người nông dân phát hiện sớm mầm bệnh ngay tại vườn, từ đó tối ưu hóa lượng thuốc bảo vệ thực vật, giảm thiểu rủi ro mất mùa và nâng cao hiệu quả kinh tế bền vững.

6. Đề nghị sửa chữa bổ sung:

.....
.....
.....
.....
.....

7. Đánh giá:

.....
.....
.....

Vĩnh Long, ngày tháng năm 20...
Giảng viên hướng dẫn
(Ký & ghi rõ họ tên)

Phạm Minh Đường

BẢN NHẬN XÉT ĐỒ ÁN TỐT NGHIỆP

(Của cán bộ chấm đồ án, khóa luận)

Họ và tên người nhận xét:

Chức danh: Học vị:

Chuyên ngành:

Cơ quan công tác:

Tên sinh viên:

Tên đề tài đồ án, khóa luận tốt nghiệp:

.....
.....

I. Ý KIẾN NHẬN XÉT

1. Nội dung:

.....
.....
.....
.....
.....
.....

2. Điểm mới các kết quả của đồ án, khóa luận:

.....
.....
.....
.....
.....

3. Ứng dụng thực tế:

.....
.....
.....
.....
.....
.....

II. CÁC VẤN ĐỀ CẦN LÀM RÕ

(Các câu hỏi của giáo viên phản biện)

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

III. KẾT LUẬN

(Ghi rõ đồng ý hay không đồng ý cho bảo vệ đề án khóa luận tốt nghiệp)

.....

.....

.....

.....

.....

Vĩnh Long, ngày tháng năm 20...

Người nhận xét

(Ký & ghi rõ họ tên)

DANH MỤC CÁC BẢNG

Bảng 3.1: Mô tả các quan hệ giữa các thực thể (collection)	27
Bảng 4.1: Phân chia số lượng ảnh theo ba tập Train/Validation/Test	49
Bảng 4.2: Cấu hình và tham số huấn luyện mô hình MobileNetV2	50
Bảng 4.3: Kết quả sau khi huấn luyện mô hình.....	51
Bảng 4.4: Kết quả Accuracy, Precision, Recall, F1-Score trên tập test	52

DANH MỤC HÌNH ẢNH

Hình 2.1: Quy trình làm việc của Machine Learning [7].....	9
Hình 2.2: Kiến trúc MobileNetV2 [5]	11
Hình 2.3: Kỹ thuật Transfer Learning trong huấn luyện mô hình [4].....	12
Hình 2.4: Minh họa Grad-CAM giải thích vùng ảnh quan	13
Hình 3.1: Kiến trúc tổng thể của hệ thống	24
Hình 3.3: Mô hình xử lý của hệ thống	30
Hình 3.4: Quy trình dự đoán bệnh (tích hợp dịch vụ Machine Learning)	31
Hình 3.5: Quy trình huấn luyện lại mô hình.....	32
Hình 4.1 Giao diện tổng quan của người dùng.....	33
Hình 4.2: Giao diện Footer của hệ thống	34
Hình 4.3: Giao diện đăng nhập của hệ thống.....	35
Hình 4.4: Giao diện quản lý vườn.....	35
Hình 4.5: Giao diện chi tiết vườn	36
Hình 4.6: Giao diện quản lý chi phí	37
Hình 4.7: Giao diện nhật ký.....	38
Hình 4.8: Giao diện dự đoán bệnh	39
Hình 4.9: Giao diện thư viện bệnh	40
Hình 4.10: Thanh menu và giao diện tổng quan của người quản trị	41
Hình 4.11: Giao diện quản lý bệnh	42
Hình 4.12: Giao diện hiển thị danh sách các kết quả dự đoán.....	42
Hình 4.13: Giao diện quản lý nhật ký ở cấp “Mùa vụ”.	43
Hình 4.14: Giao diện quản lý nhật ký cấp “Vườn”	43
Hình 4.15: Giao diện chi tiết quản lý nhật ký theo vườn.....	43
Hình 4.16: Giao diện quản lý chi phí cấp “Mùa vụ”	44

Hình 4.17: Giao diện quản lý chi phí cấp “Người dùng”	44
Hình 4.18: Giao diện quản lý chi phí cấp “Vườn”	44
Hình 4.19: Giao diện chi tiết quản lý chi phí theo vườn	45
Hình 4.20: Giao diện quản lý thông báo bình thường	45
Hình 4.21: Giao diện quản lý thông báo kiểm soát	46
Hình 4.22: Giao diện chức năng kiểm soát vườn từ thông báo kiểm soát	46
Hình 4.23: Giao diện quản lý phân bón.....	46
Hình 4.24: Giao diện quản lý thuốc	47
Hình 4.25: Giao diện chức năng huấn luyện mô hình và bảo trì hệ thống	48
Hình 4.26: Ví dụ ảnh Card-CAM bệnh loét.....	53
Hình 4.27: Ví dụ ảnh Card-CAM bệnh vàng lá gân xanh.....	53
Hình 4.28: Ví dụ ảnh Card-CAM bệnh đốm đen	54

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT

Từ viết tắt	Thuật ngữ tiếng Anh đầy đủ	Nghĩa tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
ANN	Artificial Neural Network	Mạng thần kinh nhân tạo
API	Application Programming Interface	Giao diện lập trình ứng dụng
BSON	Binary JSON	Định dạng ký pháp đối tượng JavaScript mã hóa nhị phân
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
CRUD	Create, Read, Update, Delete	Khởi tạo, Đọc, Cập nhật, Xóa
DOM	Document Object Model	Mô hình đối tượng tài liệu
FN	False Negative	Âm tính giả (Dự đoán sai là không mắc bệnh)
FP	False Positive	Dương tính giả (Dự đoán sai là có mắc bệnh)
Grad-CAM	Gradient-weighted Class Activation Mapping	Bản đồ nhiệt kích hoạt lớp dựa trên trọng số Gradient
HTTP	Hypertext Transfer Protocol	Giao thức truyền tải siêu văn bản
JSON	JavaScript Object Notation	Định dạng ký pháp đối tượng JavaScript
JSX	JavaScript Extension	Cú pháp mở rộng JavaScript
NoSQL	Not Only SQL	Hệ quản trị cơ sở dữ liệu phi quan hệ
REST	Representational State Transfer	Chuyển đổi trạng thái mang tính đại diện
SQL	Structured Query Language	Ngôn ngữ truy vấn mang tính cấu trúc

TN	True Negative	Âm tính thật (Dự đoán đúng là không mắc bệnh)
TP	True Positive	Dương tính thật (Dự đoán đúng là có mắc bệnh)
UI	User Interface	Giao diện người dùng
URL	Uniform Resource Locator	Trình định vị tài nguyên đồng dạng

CHƯƠNG 1: ĐẶT VẤN ĐỀ

1.1. Lý do chọn đề tài

Nông nghiệp đóng vai trò quan trọng trong nền kinh tế Việt Nam, đặc biệt là cây cam, một trong những loại cây ăn trái chủ lực mang lại giá trị kinh tế cao cho người nông dân tại khu vực Đồng bằng sông Cửu Long nói chung và tỉnh Vĩnh Long nói riêng [8]. Tuy nhiên, việc quản lý vườn cây theo phương thức truyền thống vẫn còn gặp nhiều khó khăn trong việc theo dõi chi phí, mùa vụ và nhật ký canh tác.

Bên cạnh đó, dịch bệnh trên cây trồng là một trong những nguyên nhân chính gây thiệt hại về năng suất và chất lượng. Việc phát hiện bệnh sớm thường dựa vào kinh nghiệm chủ quan, dẫn đến xử lý chậm trễ hoặc lạm dụng thuốc bảo vệ thực vật [10]. Với sự phát triển của trí tuệ nhân tạo (AI), đặc biệt là lĩnh vực Thị giác máy tính (Computer Vision) và Machine Learning, việc tự động hóa nhận diện bệnh qua hình ảnh lá hoặc quả của cây đã trở nên khả thi và chính xác [24].

Chính vì vậy, đề tài “Xây dựng hệ thống quản lý vườn cây và hỗ trợ dự đoán một số bệnh trên cây có múi” được thực hiện nhằm kết hợp giữa quản lý sản xuất nông nghiệp và công nghệ AI, giúp nông dân tối ưu hóa quy trình canh tác và bảo vệ cây trồng hiệu quả hơn.

1.2. Mục tiêu nghiên cứu

Thứ nhất, xây dựng hệ thống quản lý vườn cây toàn diện, cho phép người dùng dễ dàng quản lý thông tin tổng thể của vườn, phân chia các khu vực cây trồng, theo dõi sát sao nhật ký canh tác, quản lý chi phí đầu vào và lưu trữ lịch sử các loại bệnh dịch đã phát sinh trên từng cây hoặc khu vực một cách có hệ thống.

Thứ hai, ứng dụng trí tuệ nhân tạo, cụ thể là mô hình học sâu MobileNetV2 kết hợp kỹ thuật Transfer Learning và công cụ trực quan hóa bản đồ nhiệt kích hoạt lớp dựa trên gradient (Grad-CAM) để xây dựng chức năng chẩn đoán, dự đoán một số bệnh phổ biến trên cây cam thông qua hình ảnh. Chức năng này nhằm hỗ trợ người nông dân nhận diện chính xác bệnh lý lâm sàng và hiểu rõ căn cứ đưa ra quyết định của AI ngay trên thiết bị của mình.

Thứ ba, tích hợp tính năng trợ lý ảo hỗ trợ tư vấn canh tác thông qua giao diện lập trình ứng dụng (API) của Gemini AI nhằm tự động xử lý và cung cấp các lời khuyên, biện pháp điều trị dịch bệnh bằng tiếng Việt một cách hữu ích, trực quan và kịp thời cho nhà vườn.

Cuối cùng, xây dựng giao diện người dùng thân thiện, trực quan, dễ sử dụng cho cả đối tượng nông dân trực tiếp sản xuất và cán bộ quản lý nông nghiệp. Đồng thời, đảm bảo hệ thống phần mềm (Backend & Frontend) vận hành ổn định, bảo mật dữ liệu tốt, có tính ứng dụng thực tiễn cao trong nông nghiệp thông minh và sẵn sàng khả năng mở rộng các tính năng trong tương lai.

1.3. Nội dung nghiên cứu

Để hiện thực hóa trọn vẹn các mục tiêu đặt ra, các nhiệm vụ và nội dung công việc của đề tài được phân định rõ ràng thành các khối nghiên cứu trọng tâm sau đây:

Trước hết, đề tài tập trung vào công tác khảo sát thực tế để xác định bài toán nghiệp vụ, từ đó phân tích toàn diện các yêu cầu chức năng (quản lý mùa vụ, chi phí, nhật ký canh tác, chẩn đoán bệnh) và các yêu cầu phi chức năng (tính bảo mật, thời gian phản hồi, hiệu năng) phù hợp với đối tượng nhà vườn và cán bộ kỹ thuật nông nghiệp.

Tiếp theo, đi sâu vào nghiên cứu cơ sở lý thuyết và các giải pháp công nghệ cốt lõi. Nội dung bao gồm việc làm rõ cơ chế kiến trúc Client-Server, chuẩn giao tiếp dữ liệu RESTful API, hệ quản trị cơ sở dữ liệu MongoDB, môi trường chạy Node.js kết hợp khung làm việc ExpressJS phía Back-end và thư viện ReactJS phía Front-end. Đối với phân hệ trí tuệ nhân tạo, đề tài tập trung nghiên cứu sâu về ngôn ngữ Python, hệ sinh thái TensorFlow và Gemini AI.

Đồng thời, nghiên cứu chuyên sâu về biểu hiện lâm sàng của các loại bệnh phổ biến trên cây cam. Trên cơ sở đó, tiến hành thu thập, phân loại, áp dụng các kỹ thuật tăng cường dữ liệu ảnh (Data Augmentation) để xây dựng bộ dữ liệu hình ảnh lá và quả của cây đạt chuẩn, phục vụ trực tiếp cho việc huấn luyện mạng nơ-ron tích chập (CNN).

Cuối cùng, hướng đến việc thiết kế kiến trúc và hiện thực hóa mã nguồn phần mềm. Đề tài tiến hành xây dựng và huấn luyện mô hình học sâu MobileNetV2 bằng kỹ thuật Transfer Learning, kết hợp công cụ giải thích mô hình Grad-CAM [29], [30]; đồng thời lập

trình hoàn chỉnh hệ thống. Sau khi mô hình AI được tích hợp vào hệ thống, hệ thống sẽ được kiểm thử toàn diện và đánh giá kết quả để đảm bảo đáp ứng đúng yêu cầu đề ra.

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đề tài hướng đến việc nghiên cứu các hoạt động nghiệp vụ trong quy trình tổ chức, vận hành và quản lý thông tin canh tác nông nghiệp của đối tượng nhà vườn trực tiếp sản xuất cùng các cán bộ chuyên trách kỹ thuật.

Nghiên cứu về các đặc trưng hình thái học, dấu hiệu thương tổn lâm sàng và cơ chế phát sinh của một số loại bệnh hại phổ biến xuất hiện trên bề mặt lá và quả của cây cam (như bệnh loét, bệnh vàng lá gân xanh, sâu vẽ bùa và một số bệnh lý thường gặp khác).

Nghiên cứu cơ sở toán học của kiến trúc mạng nơ-ron học sâu MobileNetV2, kết hợp phương pháp chuyển giao tri thức (Transfer Learning) và giải pháp trực quan hóa bản đồ nhiệt Grad-CAM phục vụ bài toán nhận dạng ảnh thực vật.

Nghiên cứu mô hình kiến trúc phần mềm Client-Server, các tiêu chuẩn thiết kế hệ thống giao tiếp dữ liệu RESTful API, cùng hệ sinh thái công nghệ lập trình Web và Trí tuệ nhân tạo hiện đại bao gồm: thư viện ReactJS, môi trường chạy Node.js, khung làm việc ExpressJS, hệ quản trị cơ sở dữ liệu MongoDB, ngôn ngữ Python và thư viện TensorFlow.

Nghiên cứu cơ chế kết nối và giao tiếp dữ liệu bất đồng bộ với API của các mô hình ngôn ngữ lớn nhằm hiện thực hóa phân hệ trợ lý ảo tư vấn.

1.4.2. Phạm vi nghiên cứu

Đề tài giới hạn phạm vi thực hiện trong việc xây dựng và triển khai một nền tảng ứng dụng web hoàn chỉnh hoàn chỉnh phục vụ quản lý và hỗ trợ canh tác nông nghiệp. Mặc dù đối tượng nghiên cứu thuộc nhóm cây có múi, đề tài tập trung chuyên sâu vào cây cam nhằm đảm bảo tính cụ thể và hiệu quả trong quá trình phân tích và phát triển hệ thống.

Hệ thống tập trung giải quyết các bài toán cốt lõi bao gồm: quản lý tổng thể thông tin dữ liệu vườn cây, ghi nhật ký canh tác và tích hợp mô hình AI để tự động chẩn đoán, dự đoán một số bệnh lý biểu hiện qua ảnh chụp lá hoặc quả của cây cam như bệnh loét, bệnh sâu vẽ bùa, bệnh vàng lá gân xanh...

Hệ thống được thiết kế tối ưu để vận hành thực nghiệm trong phạm vi quản lý một Hợp tác xã nông nghiệp quy mô địa phương, hỗ trợ kết nối thông tin giữa Ban điều hành Hợp tác xã và quần thể các hộ nông dân thành viên trực thuộc khu vực.

1.5. Phương pháp nghiên cứu

1.5.1. Phương pháp nghiên cứu lý thuyết

Thu thập và phân tích tài liệu: Phương pháp này được sử dụng để tiếp cận, nghiên cứu các công trình khoa học, bài báo quốc tế, sách chuyên ngành và các tài liệu kỹ thuật chính thống về trí tuệ nhân tạo, Thị giác máy tính và kiến trúc học sâu MobileNetV2.

Tổng hợp và tối ưu hóa giải pháp: Trên cơ sở lý thuyết thu thập được, tiến hành tổng hợp, đánh giá ưu - nhược điểm của các giải pháp công nghệ hiện đại bao gồm mô hình kiến trúc Client-Server, tiêu chuẩn giao tiếp RESTful API, hệ sinh thái Node.js/Express, thư viện ReactJS và hệ quản trị cơ sở dữ liệu MongoDB. Từ đó, định hình nên khung kiến trúc phần mềm tối ưu cho bài toán quản lý tập trung tại Hợp tác xã.

1.5.2. Phương pháp nghiên cứu khảo sát

Khảo sát nghiệp vụ thực tế: Tiến hành khảo sát, phân tích các hoạt động vận hành đặc thù trong mô hình Hợp tác xã. Phương pháp này giúp đặc tả chính xác nhu cầu thực tế của Ban quản lý (giám sát thành viên, theo dõi tình hình dịch bệnh, chi phí) và nhu cầu của các hộ nông dân (ghi nhật ký canh tác, gửi ảnh báo bệnh), làm nền tảng xây dựng các yêu cầu chức năng cho hệ thống.

Khảo sát dữ liệu hình ảnh bệnh lý: Khảo sát các nguồn tài liệu kỹ thuật nông nghiệp thực tế về biểu hiện tổn thương lâm sàng của cây cam; đồng thời tìm kiếm, thu thập các bộ dữ liệu ảnh thực vật mã nguồn mở uy tín trên thế giới để chọn lọc, chuẩn hóa tập dữ liệu ảnh lá và quả của cây đạt chuẩn phục vụ bài toán huấn luyện AI.

1.5.3. Phương pháp nghiên cứu thực nghiệm

Thực nghiệm xây dựng mô hình AI: Triển khai cài đặt, huấn luyện mô hình dự đoán bệnh trên ngôn ngữ Python với hệ sinh thái TensorFlow thông qua kỹ thuật Transfer Learning. Sử dụng các chỉ số thống kê tiêu chuẩn bao gồm Accuracy, Loss, Precision,

Recall và F1-score để đo lường, liên tục tinh chỉnh siêu tham số và đánh giá năng lực phân loại bệnh lý của mô hình.

Thực nghiệm tích hợp và kiểm thử hệ thống: Tiến hành hiện thực hóa mã nguồn phần mềm, xây dựng hoàn chỉnh hệ thống và kết nối API với mô hình học sâu cùng trợ lý ảo Gemini AI. Sau đó, áp dụng các kịch bản kiểm thử chức năng và kiểm thử hiệu năng tổng thể để đánh giá tính ổn định, tốc độ phản hồi và khả năng ứng dụng thực tế của toàn bộ hệ thống trước khi vận hành chính thức.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về hệ thống thông tin và ứng dụng web

Hệ thống thông tin là một tập hợp các thành phần (phần cứng, phần mềm, dữ liệu và con người) tương tác với nhau nhằm thu thập, xử lý, lưu trữ và truyền đạt thông tin phục vụ cho việc ra quyết định.

2.1.1. Tìm hiểu về kiến trúc Client-Server

Về mặt vận hành, các ứng dụng web hiện đại hoạt động dựa trên mô hình kiến trúc phân tán Client-Server (Khách - Chủ), chia hệ thống thành hai thực thể độc lập giao tiếp qua mạng:

Phía Client (Khách): Là lớp giao diện người dùng, hiển thị trên các trình duyệt web. Chịu trách nhiệm tiếp nhận các thao tác của người dùng, xử lý logic hiển thị đồ họa và gửi các yêu cầu dữ liệu lên máy chủ. Trong đề tài này, phía Client được hiện thực hóa bằng thư viện ReactJS [26].

Phía Server (Chủ): Là hệ thống máy chủ từ xa chịu trách nhiệm tiếp nhận, điều phối và xử lý toàn bộ các logic nghiệp vụ của hệ thống (quản lý mùa vụ, tính toán chi phí, dự đoán bệnh). Trong đề tài, vai trò này do môi trường Node.js kết hợp khung làm việc ExpressJS đảm nhiệm [27], [28].

Thành phần Cơ sở dữ liệu (Database): Nơi lưu trữ có cấu trúc toàn bộ dữ liệu lịch sử canh tác, thông tin các vườn và nhật ký dịch bệnh, vận hành thông qua hệ quản trị cơ sở dữ liệu MongoDB.

2.1.2. Nguyên lý hoạt động của kiến trúc Client-Server

Quy trình trao đổi dữ liệu trong hệ thống diễn ra theo một chu trình khép kín bất đồng bộ bao gồm các bước [25]:

Gửi yêu cầu: Khi người dùng thực hiện một thao tác trên giao diện (ví dụ: yêu cầu xem thống kê sản lượng thu hoạch của toàn Hợp tác xã), Client sẽ đóng gói thông tin và phát đi một yêu cầu HTTP (HTTP Request) hướng tới địa chỉ của Server qua mạng Internet.

Xử lý tại Server: Máy chủ tiếp nhận HTTP Request, giải mã thông tin, thực thi các mã lệnh logic nghiệp vụ tương ứng và tiến hành truy vấn dữ liệu cần thiết từ cơ sở dữ liệu MongoDB.

Phản hồi kết quả: Sau khi có kết quả, Server tiến hành đóng gói dữ liệu vào một phản hồi HTTP (HTTP Response) và truyền ngược lại về phía Client. Trình duyệt nhận phản hồi, phân tách dữ liệu và kết xuất giao diện trực quan lên màn hình cho người dùng.

2.1.3. Tổng quan về RESTful API

Trong các hệ thống phân tán, API đóng vai trò là giao diện lập trình ứng dụng trung gian, cho phép các phân hệ phần mềm khác nhau có thể kết nối, giao tiếp và trao đổi dữ liệu mà không cần hiểu sâu về kiến trúc nội tại của nhau.

REST là một kiểu kiến trúc thiết kế phần mềm chuẩn mực tận dụng triệt để các đặc tính sẵn có của giao thức HTTP [19]. Từ đó, RESTful API được định nghĩa là hệ thống API được thiết kế tuân thủ nghiêm ngặt theo các ràng buộc và nguyên tắc của kiến trúc REST, đóng vai trò làm cầu nối đồng bộ hóa toàn bộ dòng chảy dữ liệu giữa phân hệ giao diện frontend (ReactJS) và phân hệ xử lý backend (Node.js) thông qua các lời gọi hàm tiêu chuẩn.

2.1.4. Các phương thức và thành phần cốt lõi của RESTful API

Một thiết kế hệ thống chuẩn RESTful API bắt buộc phải cấu thành từ các thành phần kỹ thuật sau [20]:

Các phương thức HTTP (HTTP Methods): Đây là tập hợp các hành động tiêu chuẩn được sử dụng để thao tác trực tiếp với tài nguyên trên máy chủ. Kiến trúc này quy định rõ bản chất từng phương thức bao gồm:

GET: Truy xuất và đọc thông tin dữ liệu từ hệ thống.

POST: Tạo mới một dữ liệu hoàn toàn mới vào hệ thống.

PUT: Cập nhật hoặc ghi đè toàn bộ thông tin của một dữ liệu đã tồn tại.

PATCH: Cập nhật cục bộ (chỉ sửa đổi một vài trường dữ liệu cụ thể) của dữ liệu.

DELETE: Loại bỏ hoặc xóa dữ liệu ra khỏi hệ thống.

Điểm cuối kết nối (Endpoint): Đường dẫn URL cụ thể mà Server cung cấp để tiếp nhận các yêu cầu tương tác từ Client.

Cấu trúc dữ liệu trao đổi (Payload): RESTful API sử dụng định dạng JSON làm ngôn ngữ chung để đóng gói dữ liệu trong cả Request (gửi lên) và Response (trả về) nhờ đặc tính gọn nhẹ, tối ưu băng thông mạng và dễ dàng phân tích cấu trúc cú pháp [14].

Mã trạng thái phản hồi (HTTP Status Codes): Các mã số tiêu chuẩn do Server trả về để thông báo kết quả xử lý cho Client (Ví dụ: 200 OK biểu thị tác vụ thành công, 401 Unauthorized biểu thị lỗi xác thực quyền truy cập, 404 Not Found biểu thị không tìm thấy tài nguyên) [20].

2.2. Tổng quan về Node.js và ExpressJS

Node.js là một môi trường chạy (Runtime Environment) mã nguồn mở và đa nền tảng, cho phép thực thi mã nguồn JavaScript ở phía máy chủ (Server-side) [27]. Được xây dựng trên V8 JavaScript Engine của Google Chrome, Node.js sử dụng mô hình kiến trúc hướng sự kiện (Event-driven) và cơ chế vòng lặp sự kiện không chặn I/O (Non-blocking I/O model) [27]. Đặc điểm này giúp Node.js tối ưu hóa hiệu suất xử lý dữ liệu, có khả năng chịu tải cao và xử lý đồng thời hàng ngàn kết nối cùng lúc mà không gây nghẽn tài nguyên hệ thống, rất phù hợp cho các ứng dụng web thời gian thực và các dịch vụ RESTful API.

Để đơn giản hóa quy trình xây dựng ứng dụng trên nền tảng Node.js, ExpressJS được sử dụng như một khung làm việc (Framework) tối giản, linh hoạt và mạnh mẽ [28]. Express cung cấp một tập hợp các tính năng mạnh mẽ để phát triển ứng dụng web và thiết lập các API định tuyến (Routing) một cách nhanh chóng [28]. Khung làm việc này hỗ trợ quản lý hiệu quả các luồng trung gian (Middleware), xử lý các yêu cầu (Request) và phản hồi (Response) từ người dùng, đồng thời dễ dàng tích hợp với các cơ sở dữ liệu NoSQL như MongoDB để phục vụ các tác vụ nghiệp vụ của hệ thống.

2.3. Tổng quan về React

React (hay ReactJS) là một thư viện JavaScript mã nguồn mở được phát triển bởi tập đoàn công nghệ Meta Platforms, chuyên dùng để xây dựng giao diện người dùng (UI), đặc biệt là cho các ứng dụng đơn trang SPA đòi hỏi tính tương tác cao [26]. React hoạt động

dựa trên kiến trúc hướng thành phần (Component-based), cho phép chia nhỏ giao diện thành các module độc lập, có khả năng tái sử dụng cao và dễ dàng quản lý mã nguồn [26].


Một trong những cải tiến cốt lõi của React là việc sử dụng cơ chế DOM ảo (Virtual DOM) [26]. Thay vì cập nhật trực tiếp lên cấu trúc DOM của trình duyệt vốn gây tốn kém hiệu năng, React sẽ tính toán sự thay đổi trên một bản sao bộ nhớ (Virtual DOM) và chỉ cập nhật những thành phần thực sự thay đổi trên giao diện. Ngoài ra, việc kết hợp cú pháp JSX giúp lập trình viên viết mã nguồn giao diện trực quan hơn công nghệ web truyền thống. Đối với hệ thống, React đóng vai trò tiếp nhận dữ liệu từ các RESTful API và hiển thị trực quan thông tin quản lý, biểu đồ thống kê cũng như kết quả dự đoán bệnh đến người dùng mà không cần tải lại toàn bộ trang web.

2.4. Tổng quan về MongoDB

MongoDB là một cơ sở dữ liệu hướng tài liệu, thuộc nhóm cơ sở dữ liệu NoSQL. Khác với các cơ sở dữ liệu quan hệ truyền thống sử dụng cấu trúc bảng, MongoDB lưu trữ dữ liệu dưới dạng các tài liệu JSON với một lược đồ rất linh hoạt gọi là BSON.

Đặc điểm cốt lõi của MongoDB là mỗi “collection” (tương đương bảng trong SQL) có thể chứa các document với kích cỡ và cấu trúc khác nhau, cho phép truy vấn dữ liệu rất nhanh chóng. Đặc điểm này cho phép MongoDB lưu trữ các kiểu dữ liệu phức tạp như mảng lồng nhau hoặc tài liệu con bên trong, giúp biểu diễn dữ liệu tự nhiên mà không cần các phép liên kết bảng gây suy giảm hiệu năng [13].

2.5. Tổng quan về Machine Learning



Hình 2.1: Quy trình làm việc của Machine Learning [7]

Machine Learning (Máy học) là một nhánh của trí tuệ nhân tạo, tập trung xây dựng hệ thống có khả năng tự học hỏi từ dữ liệu để dần cải thiện hiệu suất thực hiện một nhiệm vụ cụ thể [21]. Học có giám sát (Supervised Learning) là phương pháp phổ biến, dùng một tập dữ liệu huấn luyện đã được gán nhãn (đầu vào + đầu ra) để mô hình dự đoán [21].

Trong đề tài này, mô hình học từ bộ ảnh lá và quả của cây đã dán nhãn (như “khỏe mạnh” hay các loại bệnh) để phân loại bệnh. Học có giám sát giúp mô hình nhận biết mối quan hệ giữa đặc trưng dữ liệu và nhãn đầu ra đã cho trước.

Các mô hình mạng nơ-ron nhân tạo ANN với nhiều lớp học sâu (Deep Learning) đã chứng tỏ khả năng trích xuất và học các đặc trưng phức tạp của ảnh [21], qua đó nâng cao khả năng phân biệt giữa cây khỏe và cây nhiễm bệnh.


2.6. Tổng quan về Computer Vision trong nông nghiệp

Thị giác máy tính (Computer Vision) là lĩnh vực khoa học cho phép máy tính “nhìn” và hiểu nội dung của hình ảnh hoặc video bằng cách trích xuất và phân tích thông tin trực quan. Nói cách khác, mục tiêu của thị giác máy tính là tạo phương pháp để máy tính có thể “nhìn” và “hiểu” các đặc trưng của hình ảnh kỹ thuật số giống như con người [24].

Trong nông nghiệp, thị giác máy tính được ứng dụng rộng rãi: từ phân loại cây trồng, đếm sản lượng quả đến nhận diện sâu bệnh qua các triệu chứng trên lá hoặc quả. Các mô hình học sâu (Deep Learning), trong đó nổi bật nhất là kiến trúc mạng CNN đã chứng minh hiệu quả vượt trội trong nhận dạng ảnh cây trồng [24].

Thực tế, CNN được đánh giá là công cụ mạnh nhất để nhận biết bệnh cây qua ảnh lá hoặc quả và đã trở thành hướng tiếp cận chuẩn mực trong lĩnh vực này. Những ưu điểm này cho phép xây dựng hệ thống chẩn đoán bệnh tự động, hỗ trợ nông dân phát hiện sớm và chính xác các loại bệnh thực vật.

2.7. Mô hình MobileNetV2




Hình 2.2: Kiến trúc MobileNetV2 [5]

MobileNetV2 là một kiến trúc mạng CNN hiệu quả được thiết kế tối ưu cho các thiết bị di động và nhúng có tài nguyên hạn chế. Kiến trúc này nổi bật bởi việc sử dụng depthwise separable convolutions (tách tích chập theo kênh) thay cho các lớp tích chập truyền thống. Cụ thể, tính toán của mỗi lớp Depthwise Separable bao gồm hai bước: tích chập theo chiều sâu (depthwise convolution) áp dụng bộ lọc 3×3 riêng cho từng kênh đầu vào, sau đó là tích chập 1×1 (pointwise convolution) để kết hợp thông tin giữa các kênh. Cách làm này giảm đáng kể số tham số và khối lượng tính toán (ví dụ giảm $\sim 8-9$ lần so với convolution thông thường) mà vẫn duy trì độ chính xác cao [30].

Một cải tiến quan trọng khác của MobileNetV2 là Inverted Residual Block và Linear Bottleneck: mỗi khối tăng chiều không gian đặc trưng rồi nén lại qua một lớp “cổ chai” tuyến tính. Thiết kế đảo ngược này giúp giữ thông tin quan trọng xuyên suốt mạng, giảm thiểu mất mát thông tin và gia tăng độ chính xác chung [30]. Nhờ các kỹ thuật trên, MobileNetV2 đạt khả năng biểu diễn cao mà không tăng đáng kể độ phức tạp tính toán, phù hợp cho việc triển khai trên thiết bị di động.

Trong đề tài này, kiến trúc MobileNetV2 được lựa chọn làm giải pháp cốt lõi cho phân hệ trí tuệ nhân tạo nhằm giải quyết triệt để bài toán tối ưu hóa hiệu năng và chi phí vận hành hệ thống. Với đặc thù cấu trúc siêu nhẹ và tốc độ xử lý tính toán nhanh, mô hình cho phép các hộ nông dân thành viên và cán bộ kỹ thuật của Hợp tác xã có thể thực hiện tác vụ tải ảnh lá hoặc quả của cây và nhận kết quả chẩn đoán bệnh lý ngay tại ruộng vườn thông qua các thiết bị di động cá nhân có cấu hình phần cứng trung bình hoặc trong điều kiện kết nối mạng băng thông rộng (3G/4G) không ổn định. Đồng thời, việc ứng dụng một mô hình tiết kiệm tài nguyên phần cứng giúp hệ thống quản lý giảm thiểu tối đa tải trọng tính toán trên máy chủ, từ đó hạ thấp chi phí thuê mướn hạ tầng điện toán đám mây xuống mức tối thiểu, đảm bảo tính khả thi và khả năng duy trì vận hành lâu dài của dự án tại các tổ chức sản xuất nông nghiệp địa phương.

2.8. Kỹ thuật Transfer Learning trong nhận dạng ảnh



Hình 2.3: Kỹ thuật Transfer Learning trong huấn luyện mô hình [4]

Học chuyển giao (Transfer Learning) là kỹ thuật tận dụng một mô hình đã được huấn luyện trước trên một tập dữ liệu lớn để áp dụng vào bài toán mới nhưng có liên quan. Ý tưởng là tái sử dụng các trọng số và đặc trưng đã học của mô hình gốc, qua đó giảm thiểu thời gian huấn luyện và nhu cầu dữ liệu cho bài toán đích [29].


Trong đề tài này, giữ lại các lớp trích xuất đặc trưng từ mô hình MobileNetV2 đã huấn luyện, đồng thời thay thế hoặc huấn luyện lại lớp phân loại cuối cùng cho phù hợp

với các nhãn bệnh cụ thể cần nhận diện. Cách tiếp cận này giúp mô hình nhanh hội tụ hơn và đạt hiệu quả cao ngay cả khi tập dữ liệu không quá lớn.

2.9. Kỹ thuật Grad-CAM và Explainable AI



Ảnh gốc



Ảnh Grad-CAM

Hình 2.4: Minh họa Grad-CAM giải thích vùng ảnh quan

Explainable AI (AI có thể giải thích được) là lĩnh vực nhằm tạo ra các phương pháp để con người có thể hiểu và tin tưởng quyết định của mô hình học máy [31].

Công cụ Grad-CAM (Gradient-weighted Class Activation Mapping) là một kỹ thuật giải thích hình ảnh phổ biến cho mạng CNN. Grad-CAM sử dụng gradient của lớp đầu ra với bản đồ kích hoạt ở lớp tích chập cuối để tạo ra bản đồ nhiệt (heatmap) trên ảnh gốc. Nó khoanh vùng những khu vực ảnh mà mô hình “chú ý” nhất để đưa ra dự đoán [31].

Ví dụ, với ảnh lá cây, Grad-CAM sẽ tô đậm vùng có tổn thương (đốm, vết cháy) khiến mô hình nhận định lá bị bệnh. Nhờ đó, nông dân và chuyên gia có thể hiểu rõ hơn lý do mô hình dự báo bệnh, từ đó tin tưởng kết quả và có hướng xử lý hợp lý.

2.10. Các phương pháp đánh giá mô hình

2.9.1. Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn là một trong những công cụ trực quan và hiệu quả nhất để phân tích chi tiết năng lực phân loại của mô hình dựa trên việc đối chiếu trực tiếp giữa nhãn thực tế (Actual Class) và nhãn do mô hình dự đoán (Predicted Class) [17]. Trong kịch bản phân loại nhị phân, hệ thống giả định một trạng thái cần phát hiện làm lớp khẳng định (Positive - ví dụ: Lá cây bị bệnh sâu vẽ bùa) và trạng thái còn lại làm lớp phủ định (Negative - ví dụ: Lá cây khỏe mạnh). Cấu trúc ma trận này được cấu thành từ 4 đại lượng thống kê bao gồm:

True Positive (TP): Số lượng mẫu dữ liệu thực tế mang nhãn khẳng định và hệ thống đã đưa ra quyết định dự đoán chính xác là lớp khẳng định. Ví dụ: Mẫu ảnh thực tế nhiễm bệnh loét biểu bì và mô hình chẩn đoán đúng là bệnh loét biểu bì.

False Positive (FP): Số lượng mẫu thực tế thuộc lớp phủ định nhưng bị hệ thống phân loại sai thành lớp khẳng định (Sai lầm loại I). Ví dụ: Mẫu ảnh thực tế là lá cây lành tính nhưng mô hình dự đoán nhầm thành bệnh loét biểu bì (hiện tượng báo động giả).

False Negative (FN): Số lượng mẫu thực tế thuộc lớp khẳng định nhưng bị hệ thống nhận diện sai thành lớp phủ định (Sai lầm loại II). Ví dụ: Mẫu ảnh thực tế đã bị nhiễm bệnh loét nhưng mô hình nhận diện sót thành lá cây khỏe mạnh (hiện tượng bỏ sót mầm bệnh).

True Negative (TN): Số lượng mẫu dữ liệu thực tế mang nhãn phủ định và hệ thống đã đưa ra quyết định dự đoán chính xác là lớp phủ định. Ví dụ: Mẫu ảnh thực tế là lá cây khỏe mạnh và mô hình chẩn đoán đúng là lá cây khỏe mạnh.

Khi mở rộng sang bài toán phân loại đa lớp (Multi-class Classification) để nhận diện nhiều chủng loại bệnh lý đồng thời trên cây cam (bệnh loét, bệnh sâu vẽ bùa, bệnh vàng lá...), ma trận nhầm lẫn sẽ được phát triển thành cấu trúc ma trận vuông kích thước $N \times N$ (với N đại diện cho số lượng lớp bệnh) [17]. Lúc này, tập hợp các phần tử phân bố trên đường chéo chính sẽ phản ánh số lượng mẫu được mô hình chẩn đoán chính xác; ngược lại, các phần tử nằm ngoài đường chéo chính sẽ vạch rõ xu hướng mô hình đang bị nhầm lẫn giữa các biểu hiện bệnh lý khác nhau.

2.9.2. Độ chính xác tổng quan (Accuracy)

Chỉ số Accuracy đo lường tỷ lệ phần trăm giữa tổng số lượng mẫu được mô hình phân loại chính xác (bao gồm cả hai thiên hướng khẳng định và phủ định) trên toàn bộ tổng số lượng mẫu kiểm thử thuộc tập dữ liệu:

$$\text{Accuracy} = \frac{TP+TN}{TP+FP+FN+TN} \quad (2.1)$$

Mặc dù được sử dụng phổ biến, chỉ số này sẽ bị mất đi độ tin cậy khoa học khi tập dữ liệu kiểm thử rơi vào trạng thái mất cân bằng nghiêm trọng (Imbalanced Data) [33]. Xét ví dụ trong thực tế, nếu tập dữ liệu đánh giá chứa 960 ảnh lá cây khỏe mạnh và chỉ có 40 ảnh lá cây bị bệnh vàng lá gân xanh, một mô hình phân loại kém chất lượng chỉ cần đưa ra

dự đoán mặc định toàn bộ mẫu là lá lành thì vẫn đạt chỉ số Accuracy lên đến 96%, nhưng trên thực tế mô hình này hoàn toàn vô dụng vì thất bại hoàn toàn trong việc phát hiện ra các ổ dịch bệnh.

2.9.3. Độ chính xác của dự đoán (Precision)

Precision (còn được gọi là giá trị dự đoán dương) thể hiện tỷ lệ giữa số lượng mẫu thực tế thuộc lớp khẳng định trên tổng số lượng mẫu mà hệ thống đã đưa ra quyết định chẩn đoán là lớp khẳng định [33]:

$$\text{Precision} = \frac{TP}{TP+FP} \quad (2.2)$$

Ý nghĩa thực tiễn đối với đề tài: Chỉ số Precision đại diện cho mức độ đáng tin cậy của hệ thống AI khi phát phát đi một thông báo cảnh báo dịch bệnh. Khi mô hình đạt chỉ số Precision cao, Ban quản lý Hợp tác xã và nhà vườn có thể hoàn toàn tin tưởng rằng nếu mô hình chẩn đoán chiếc lá bị bệnh loét, thì xác suất chiếc lá đó bị nhiễm bệnh thật là cực kỳ lớn. Điều này giúp người nông dân tránh được việc đầu tư chi phí và công sức phun thuốc bảo vệ thực vật một cách lãng phí do hệ thống đưa ra báo động giả (FP).

2.9.4. Độ nhạy / Tỷ lệ thu hồi (Recall)

Chỉ số Recall (còn gọi là độ nhạy hoặc tỷ lệ tìm đúng mầm bệnh) xác định tỷ lệ giữa số lượng mẫu chẩn đoán đúng lớp khẳng định trên tổng số lượng mẫu thực tế vốn có của lớp khẳng định đó [33]:

$$\text{Recall} = \frac{TP}{TP+FN} \quad (2.3)$$

Ý nghĩa thực tiễn đối với đề tài: Trong lĩnh vực y sinh học và dịch tễ nông nghiệp, Recall là chỉ số mang tính chất sống còn. Mô hình đạt chỉ số Recall cao chứng tỏ hệ thống sở hữu năng lực quét và bao phủ toàn diện, bắt trọn hầu hết mọi dấu hiệu bệnh lý xuất hiện trong khu vực vườn cây của Hợp tác xã, giảm thiểu tối đa rủi ro bỏ sót mầm bệnh (FN). Trong thực tế tổ chức sản xuất tập trung, việc hệ thống bỏ sót một chiếc lá bị bệnh (tạo ra FN) nguy hiểm hơn rất nhiều so với việc chẩn đoán nhầm một chiếc lá lành thành lá bệnh (tạo ra FP), vì một nguồn bệnh bị bỏ sót có thể nhanh chóng bùng phát thành dịch và lây lan trên diện rộng toàn vùng.

2.9.5. Điểm F1-Score (F-measure)

Chỉ số $F1$ -Score được xây dựng nhằm giải quyết mối quan hệ mâu thuẫn nội tại giữa hai đại lượng Precision và Recall. Đây là điểm trung bình điều hòa (Harmonic Mean) đại diện cho sự cân bằng, hài hòa và tính ổn định tổng thể của một mô hình học sâu [33]:

$$F1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.4)$$

Ý nghĩa thực tiễn đối với đề tài: Giá trị $F1$ -Score chỉ tiệm cận về mức tối ưu (bằng 1) khi và chỉ khi cả hai chỉ số Precision và Recall đồng thời đạt kết quả cao. Đối với bài toán nhận diện đa lớp bệnh hại trên cây cam sử dụng kiến trúc MobileNetV2, điểm $F1$ -Score chính là thước đo khách quan, minh bạch và có giá trị nhất để chứng minh mô hình AI vận hành ổn định, đồng đều trên tất cả các nhóm bệnh lý khác nhau mà không bị thiên vị cho các nhóm dữ liệu nhiều hay bỏ quên các nhóm bệnh hiếm gặp.

2.9.6. Hàm mất mát Entropy chéo đa lớp (Categorical Cross-Entropy Loss)

Hàm mất mát (Loss function) là một đại lượng toán học đo lường mức độ sai lệch giữa xác suất dự đoán của mô hình học sâu và nhãn thực tế của mẫu dữ liệu trong quá trình huấn luyện [15]. Đối với bài toán phân loại đa lớp sử dụng hàm kích hoạt Softmax ở tầng đầu ra như kiến trúc MobileNetV2, hàm mất mát Entropy chéo đa lớp là tiêu chuẩn tối ưu được áp dụng.

Đối với một mẫu dữ liệu đơn lẻ, hàm mất mát được tính toán dựa trên sự đối chiếu giữa nhãn thực tế mã hóa dưới dạng vector One-hot y và xác suất dự đoán $\hat{y}$ từ hàm Softmax:

$$\ell(y, \hat{y}) = - \sum_{i=1}^N y_i \log(\hat{y}_i) \quad (2.5)$$

Trong đó:

N : Là tổng số lượng lớp bệnh cần phân loại (đối với đề tài là $N = 10$).

y_i : Là giá trị nhãn thực tế của lớp thứ i . Giá trị $y_i = 1$ nếu mẫu thực tế thuộc về lớp i , ngược lại $y_i = 0$.

$\hat{y}_i$: Là xác suất dự đoán của mô hình (dạng số thập phân từ 0 đến 1) cho thấy khả năng mẫu ảnh thuộc về lớp thứ i .

Trong thực tế huấn luyện, mô hình không tối ưu hóa dựa trên từng mẫu đơn lẻ mà tính toán trung bình tổn thất trên toàn bộ tập dữ liệu gồm M mẫu (hoặc trên từng lô dữ liệu - mini-batch):

$$Loss = -\frac{1}{M} \sum_{m=1}^M \sum_{i=1}^N y_i^{(m)} \log(\hat{y}_i^{(m)}) \quad (2.6)$$

Trong đó M đại diện cho kích thước của lô dữ liệu (batch size) hoặc tổng số lượng mẫu trong tập huấn luyện, còn $y_i^{(m)}$ và $\hat{y}_i^{(m)}$ lần lượt là nhãn thực tế và xác suất dự đoán lớp i của mẫu thứ m .

Trong suốt quá trình huấn luyện, giá trị Loss đóng vai trò là cơ sở định lượng giúp thuật toán tối ưu hóa (như Adam) thực hiện cơ chế lan truyền ngược (Backpropagation) để cập nhật, tinh chỉnh hệ thống trọng số (Weights) của mạng nơ-ron MobileNetV2. Khi giá trị Loss tiệm cận dần về mức 0, điều này chứng tỏ khoảng cách phân phối xác suất giữa phân loại của AI và thực tế ngoài thực địa của nhà vườn đang thu hẹp lại tối đa, mô hình ngày càng trở nên tự tin và chính xác hơn khi đưa ra quyết định.

Do hàm toán học có chứa biểu thức $\log(\hat{y}_i)$, hệ thống sẽ gặp lỗi tính toán nghiêm trọng (tràn số hoặc giá trị vô cùng) nếu mô hình dự đoán xác suất của một lớp bằng tuyệt đối 0. Để đảm bảo tính ổn định toán học, hệ thống áp dụng kỹ thuật chèn thêm một hằng số cực nhỏ ϵ (thường là $1e-7$) vào biểu thức toán hoặc sử dụng hàm liên hợp *LogSoftmax* trong quá trình huấn luyện, giúp ngăn chặn triệt để hiện tượng lỗi phép tính $\log(0)$ và giữ cho tiến trình tối ưu hóa luôn vận hành liên tục.

2.11. Một số bệnh trên cây có múi

Cây cam là cây ăn quả có giá trị kinh tế cao nhưng thường xuyên đối mặt với nhiều loại dịch hại và bệnh lý phức tạp do vi khuẩn, nấm, virus, côn trùng và các yếu tố dinh dưỡng gây ra. Trong số đó, bệnh vàng lá gân xanh (Greening) do vi khuẩn *Candidatus Liberibacter asiaticus* lây truyền qua rầy chổng cánh [2] là một trong những bệnh nguy hiểm nhất, khiến lá vàng loang lổ không đối xứng, quả nhỏ méo mó, hạt lép đen và hiện chưa có thuốc điều trị đặc hiệu ngoài việc nhổ bỏ cây bệnh và kiểm soát côn trùng môi giới. Bệnh loét hại cây có múi do vi khuẩn *Xanthomonas campestris* pv. *citri* [2] gây ra các vết loét màu nâu nhạt, xù xì, có quầng vàng sáng trên lá, quả và cành non; biện pháp khắc

phục là cắt tỉa cành bệnh, kiểm soát sâu vẽ bùa và phun phòng bằng thuốc gốc đồng. Bệnh xoắn lá chủ yếu do các loài Virus (như Citrus Tristeza Virus, Citrus Vein Enation Virus) hoặc do nấm và côn trùng chích hút [1] khiến lá non biến dạng, co dúm, làm giảm diện tích quang hợp; nhà vườn cần tiêu hủy cành bệnh, diệt côn trùng môi giới và bổ sung dinh dưỡng qua lá. Đối với các bệnh do nấm, bệnh đốm dầu do *Mycosphaerella citri* [2] tạo ra các đốm màu vàng đến nâu đen bóng loáng như vết dầu ở mặt dưới lá, gây rụng lá hàng loạt; trong khi bệnh đốm đen do *Phyllosticta citricarpa* [3] tạo ra các đốm tròn màu nâu nhạt có viền vàng trên cả lá và quả, làm giảm chất lượng thương phẩm. Cả hai bệnh do nấm này đều cần khắc phục bằng cách vệ sinh vườn tược, giảm độ ẩm tán lá và phun thuốc đặc trị nấm chuyên dụng.

Về mặt dịch hại do côn trùng, sâu vẽ bùa (*Phyllocnistis citrella*) [2] gây hại phổ biến trên đợt non bằng cách đục màng tế bào tạo các đường rãnh ngoằn ngoèo, làm lá co cụm và tạo cửa ngõ cho vi khuẩn loét xâm nhập; cách phòng trừ hiệu quả là thúc cây ra đợt đồng loạt và bảo vệ thiên địch như kiến vàng. Bên cạnh đó, các loài sâu ăn lá như sâu tơ, sâu xanh [9] cắn phá trực tiếp tạo lỗ thủng hoặc khuyết mép lá, cần được phòng trừ bằng cách bắt tay hoặc dùng chế phẩm sinh học. Khi cây bị tấn công đồng thời bởi nhiều tác nhân hoặc suy kiệt do thiếu dinh dưỡng, trạng thái bệnh hỗn hợp xảy ra với các triệu chứng chồng chéo, đòi hỏi phải cách ly cây, cắt bỏ bộ phận tổn thương và điều chỉnh chế độ chăm sóc. Ngoài các tác nhân sinh học, tình trạng thiếu dinh dưỡng là bệnh lý phi sinh vật xuất hiện do chế độ bón phân không cân đối hoặc đất bị chua; biểu hiện qua việc lá già bị vàng (thiếu Đạm), lá nhỏ nhuốm tím (thiếu Lân), cháy mép lá (thiếu Kali) hoặc lá non biến dạng (thiếu vi lượng), cần khắc phục bằng cách thiết kế lại quy trình bón phân NPK kết hợp bổ sung vi lượng [6]. Ngược lại, trạng thái khỏe mạnh phản ánh cây được chăm sóc tốt trong điều kiện lý tưởng với biểu hiện cây phát triển cân đối, lá xanh mướt, quả đồng đều và rễ phát triển mạnh; trạng thái này cần được duy trì bằng quy trình bón phân hữu cơ định kỳ và cắt tỉa cành thông thoáng để hạn chế mầm bệnh phát sinh.

2.12. Các công trình nghiên cứu liên quan

Trong những năm gần đây, xu hướng giao thoa giữa Trí tuệ nhân tạo và Nông nghiệp thông minh đã mở ra nhiều hướng tiếp cận mới trong việc bảo vệ mùa màng. Nhiều học giả trên thế giới và tại Việt Nam đã tập trung khai thác các mô hình học sâu nhằm tự động

hóa quy trình phát hiện dịch bệnh thực vật qua hình ảnh. Dưới đây là các công trình khoa học tiêu biểu được đề tài tham khảo, kế thừa và phân tích nhằm làm cơ sở luận cứ:

Thứ nhất, Sladojevic và cộng sự (2016): đã triển khai một hệ thống mạng nơ-ron tích chập chuyên sâu để nhận diện bệnh cây qua ảnh lá, thử nghiệm với 13 loại bệnh trên 5 loại cây khác nhau, cho kết quả chính xác từ 91% đến 98% [32]. Ưu điểm: Khẳng định rõ ràng năng lực vượt trội của các kiến trúc học sâu trong việc tự động trích xuất các tầng đặc trưng hình thái học phức tạp trực tiếp từ dữ liệu ảnh gốc mà không cần con người can thiệp tách lọc thủ công. Khuyết điểm: Mô hình mới chỉ được đánh giá trong môi trường thực nghiệm với các góc chụp tiêu chuẩn, chưa đo lường độ ổn định khi đối mặt với dữ liệu ảnh thực địa có chứa nhiều thành phần nhiễu tự nhiên như ảnh mờ, ngược sáng hoặc lá bị che khuất.

Thứ hai, Ferentinos (2018): Xây dựng nhiều mô hình học sâu (CNN) trên bộ dữ liệu mở khoảng 87.848 ảnh gồm 58 lớp (25 loại cây, bao gồm cả cây khỏe), mô hình tốt nhất đạt độ chính xác 99,53% khi phân loại bệnh trên ảnh mới [18]. Ưu điểm: Cung cấp một báo cáo thực nghiệm toàn diện và tường minh về hiệu năng xử lý của nhiều dòng kiến trúc tích chập khác nhau, tạo cơ sở lý thuyết vững chắc cho việc lựa chọn bộ phân lớp bệnh thực vật. Khuyết điểm: Có dấu hiệu bị quá khớp (Overfitting) với điều kiện chụp hoàn hảo của phòng thí nghiệm; khi ứng dụng vào ảnh thực tế chụp tại các nông trường, độ chính xác có xu hướng bị sụt giảm do sự khác biệt lớn về ngữ cảnh môi trường.

Thứ ba, Howard và cộng sự (2017): Giới thiệu kiến trúc MobileNets - một mô hình CNN hiệu quả dành cho thiết bị di động, sử dụng phép tích chập phân tách (depthwise separable) để giảm thiểu tham số trong khi vẫn giữ độ chính xác cao. Đây là tiền đề quan trọng cho MobileNetV2 được áp dụng trong đề tài [22]. Ưu điểm: Mang lại bước đột phá lớn trong việc tối ưu hóa cấu trúc thuật toán và tiết kiệm tài nguyên tính toán, mở ra cơ hội đưa các mô hình AI lên vận hành ổn định trên các thiết bị phần cứng hạn chế. Khuyết điểm: Khảo sát ban đầu của nhóm tác giả mới chỉ tập trung giải quyết bài toán phân loại vật thể tổng quát (Object Classification), chưa đi sâu vào việc tinh chỉnh và đánh giá năng lực phân tách trên các tập dữ liệu dịch bệnh nông nghiệp có độ tương đồng cao.

Thứ tư, Hughes và Salathe (2015): Xây dựng bộ dữ liệu mở PlantVillage gồm hơn 50.000 ảnh lá cây ở trạng thái khỏe và nhiễm bệnh. Dữ liệu này đã trở thành nền tảng cho nhiều nghiên cứu về nhận dạng bệnh cây bằng thị giác máy tính [23]. Ưu điểm: Giải quyết

triệt để bài toán khan hiếm dữ liệu thực vật, cung cấp nguồn ảnh phong phú được gán nhãn chính xác bởi các chuyên gia để cộng đồng khoa học có cơ sở huấn luyện mô hình. Khuyết điểm: Các mẫu ảnh hầu hết được chụp trên một phong nền nhân tạo đồng nhất (màu xám hoặc đen), dẫn đến việc thiếu hụt tính đa dạng về bối cảnh tự nhiên so với môi trường canh tác thực tế ngoài đồng ruộng.

Thứ năm, Nguyễn Hồng Quyền và các cộng sự (2020) đã thực hiện đề tài nghiên cứu nhận diện tự động một số bệnh phổ biến trên cây cam tại khu vực Đồng bằng sông Cửu Long. Nhóm tác giả sử dụng mạng CNN truyền thống để huấn luyện và phân loại các mẫu ảnh bệnh loét lá và bệnh vàng lá gân xanh (Greening) được thu thập trực tiếp tại các nhà vườn địa phương [11]. Ưu điểm: Đề tài mang giá trị thực tiễn cao tại Việt Nam khi sử dụng nguồn dữ liệu ảnh bản địa, bám sát các đặc điểm dịch tễ và điều kiện ánh sáng thực tế của cây trồng trong nước. Khuyết điểm: Việc vận hành dòng mạng CNN truyền thống khiến mô hình sở hữu lượng tham số lớn, tốc độ xử lý chậm và tốn tài nguyên, gây khó khăn lớn cho việc tích hợp vào các hệ thống Web để chạy theo thời gian thực.

Nhìn chung, hệ thống các công trình nghiên cứu tiền đề đã khẳng định tiềm năng to lớn của học sâu trong nông nghiệp chính xác, đồng thời cung cấp cho đề tài này một hệ thống cơ sở dữ liệu vững chắc, kiến trúc mạng nền tảng tối ưu cùng phương pháp luận phân loại hiệu quả. Dù vậy, một rào cản chung của các nghiên cứu quốc tế là hầu như chỉ vận hành trong môi trường dữ liệu đóng của phòng thí nghiệm, chưa được tối ưu cho đặc thù dịch bệnh tại Việt Nam. Ngược lại, các nghiên cứu trong nước dù bám sát thực địa nhưng lại vướng phải hạn chế về mặt công nghệ, gây tốn kém chi phí vận hành hạ tầng.

Tuy nhiên, điểm hạn chế cốt lõi và là khoảng trống nghiên cứu lớn nhất hiện nay là tất cả các công trình nêu trên chỉ tiếp cận bài toán dưới góc độ xây dựng một công cụ AI nhận diện bệnh lý độc lập. Hoàn toàn chưa có một công trình nào tiến hành tích hợp mô hình chẩn đoán này vào trong một nền tảng quản lý nông nghiệp tập trung mang tính liên kết như mô hình Hợp tác xã. Đây là nơi có nhu cầu rất lớn về việc số hóa thông tin, phân quyền thành viên, ghi nhật ký canh tác chéo, theo dõi chi phí đầu vào và lưu trữ lịch sử dịch bệnh theo từng mùa vụ của từng nhà vườn thành viên trong khu vực.

Từ đó, đề tài “Xây dựng hệ thống quản lý vườn cây và hỗ trợ dự đoán một số bệnh trên cây có múi” được triển khai nhằm mang đến một giải pháp công nghệ toàn diện. Hệ

thông không chỉ giải quyết bài toán quản lý tập trung cho Ban quản lý Hợp tác xã, mà còn tích hợp mô hình học sâu siêu nhẹ MobileNetV2 (kế thừa nguyên lý tích chập tách biệt chiều sâu) kết hợp kỹ thuật trực quan hóa Grad-CAM và trợ lý AI Gemini AI. Giải pháp này giúp người nông dân chẩn đoán bệnh tức thời ngay tại vườn với độ trễ thấp nhất, đồng thời tối ưu hóa chi phí thuê mướn máy chủ cho Hợp tác xã, đảm bảo tính khả thi cao khi ứng dụng vào thực tế sản xuất tại Việt Nam.

CHƯƠNG 3: HIỆN THỰC HÓA NGHIÊN CỨU

3.1. Mô tả hệ thống

Hệ thống quản lý vườn cây và hỗ trợ dự đoán bệnh trên cây có múi là một ứng dụng web phục vụ cho việc quản lý thông tin canh tác, theo dõi tình hình vườn cây, ghi nhận nhật ký chăm sóc, quản lý chi phí và hỗ trợ nhận diện bệnh trên lá cây thông qua mô hình học sâu. Hệ thống được xây dựng theo mô hình ứng dụng web hiện đại, trong đó phần giao diện người dùng được phát triển bằng React kết hợp TailwindCSS, phần xử lý nghiệp vụ được xây dựng bằng Node.js và Express, dữ liệu được lưu trữ trong MongoDB, còn chức năng dự đoán bệnh được triển khai bằng Python, TensorFlow và Flask.

Mục tiêu chính của hệ thống là hỗ trợ quản lý hoạt động canh tác một cách có hệ thống, đồng thời cung cấp công cụ nhận diện bệnh từ ảnh lá cây nhằm giúp người dùng phát hiện sớm tình trạng bất thường và có biện pháp xử lý kịp thời. Bên cạnh đó, hệ thống còn cho phép quản trị viên quản lý dữ liệu bệnh, quản lý người dùng, cập nhật thông tin hỗ trợ điều trị, quản lý phân bón và thuốc, cũng như theo dõi quá trình huấn luyện lại mô hình học máy khi có dữ liệu mới.

Vai trò của hệ thống thể hiện ở hai khía cạnh. Thứ nhất, hệ thống đóng vai trò là công cụ quản lý hỗ trợ hoạt động canh tác, giúp số hóa các thông tin về vườn cây, mùa vụ, nhật ký chăm sóc và chi phí phát sinh. Thứ hai, hệ thống đóng vai trò là công cụ hỗ trợ chẩn đoán ban đầu, cho phép người dùng tải ảnh lá cây lên để nhận kết quả dự đoán bệnh từ mô hình trí tuệ nhân tạo. Nhờ đó, hệ thống không chỉ hỗ trợ quản lý mà còn góp phần nâng cao hiệu quả phòng bệnh cho cây trồng.

Đối tượng sử dụng của hệ thống gồm hai nhóm chính. Nhóm thứ nhất là người dùng thông thường, bao gồm các chủ vườn hoặc người trực tiếp canh tác, có nhu cầu quản lý vườn cây, ghi nhật ký, theo dõi chi phí, chụp ảnh lá cây để dự đoán bệnh và tra cứu thông tin bệnh. Nhóm thứ hai là quản trị viên hệ thống, có quyền quản lý toàn bộ dữ liệu, kiểm duyệt và cập nhật thông tin bệnh, quản lý người dùng, quản lý các danh mục hỗ trợ, theo dõi kết quả huấn luyện mô hình và bật hoặc tắt chế độ bảo trì khi cần thiết.

3.2. Các chức năng của hệ thống

Hệ thống được thiết kế theo hướng phân quyền chức năng rõ ràng giữa người dùng và quản trị viên, trong đó mỗi nhóm người dùng được cung cấp các chức năng phù hợp với vai trò của mình.

Đối với người dùng thông thường, hệ thống hỗ trợ chức năng đăng nhập tài khoản nhằm đảm bảo quá trình sử dụng được gắn với từng cá nhân cụ thể. Sau khi đăng nhập, người dùng có thể quản lý danh sách vườn cây của mình, bao gồm thêm mới mẫu trong vườn, chỉnh sửa thông tin vườn. Mỗi vườn có thể gắn với mùa vụ canh tác tương ứng, giúp việc theo dõi trở nên thuận tiện và có tổ chức hơn.

Bên cạnh quản lý vườn, hệ thống còn cho phép người dùng ghi nhận nhật ký canh tác. Đây là chức năng lưu lại các hoạt động như chăm sóc, bón phân, phun thuốc hoặc theo dõi tình trạng sinh trưởng của cây. Thông tin nhật ký giúp người dùng truy xuất lịch sử canh tác theo thời gian, từ đó dễ dàng đánh giá hiệu quả chăm sóc.

Hệ thống cũng có chức năng quản lý chi phí. Người dùng có thể nhập các khoản chi liên quan đến cây trồng, vật tư, phân bón, thuốc bảo vệ thực vật hoặc chi phí lao động. Các khoản chi này được tổng hợp để hỗ trợ người dùng theo dõi tình hình đầu tư và đánh giá hiệu quả kinh tế của từng vườn cây.

Một chức năng nổi bật của hệ thống là dự đoán bệnh từ ảnh lá cây. Người dùng tải ảnh lên hệ thống, sau đó mô hình học máy sẽ xử lý ảnh và trả về kết quả dự đoán bệnh có xác suất cao nhất. Ngoài kết quả chính, hệ thống còn hiển thị top các dự đoán có độ tin cậy cao để người dùng tham khảo thêm. Chức năng này giúp người dùng nhận biết sớm các dấu hiệu bệnh trên cây cam, từ đó chủ động xử lý.

Ngoài ra, người dùng còn có thể tra cứu thư viện bệnh cây. Phần này cung cấp thông tin chi tiết về các loại bệnh, nguyên nhân, triệu chứng, mức độ nguy hiểm và hướng xử lý. Đây là chức năng hỗ trợ người dùng hiểu rõ hơn về bệnh lý thực vật, không chỉ phụ thuộc vào kết quả dự đoán của mô hình.

Đối với quản trị viên, hệ thống cung cấp các chức năng quản lý ở mức toàn cục. Quản trị viên có thể quản lý danh sách người dùng, theo dõi và cập nhật thông tin vườn cây, quản lý danh mục bệnh, mùa vụ, công việc và các dữ liệu hỗ trợ khác. Quản trị viên cũng có


quyền xem nhật ký canh tác, chi phí và nhật ký bệnh. Ngoài ra, Quản trị viên còn có thể tạo các thông báo để gửi đến toàn bộ hoặc một nhóm người dùng để thông báo hoặc giám sát.

Đặc biệt, hệ thống còn tích hợp trang huấn luyện mô hình dành cho quản trị viên. Tại đây, quản trị viên có thể tải thêm ảnh mẫu bệnh mới, khởi động quá trình huấn luyện lại mô hình và theo dõi các chỉ số đánh giá như accuracy, loss, precision, recall và F1-score. Đây là chức năng quan trọng để bảo đảm mô hình có thể được cập nhật theo dữ liệu thực tế phát sinh trong quá trình sử dụng.

Ngoài các chức năng chuyên môn, hệ thống còn hỗ trợ chế độ bảo trì toàn hệ thống. Khi chế độ này được bật bởi quản trị viên, người dùng thông thường sẽ thấy thông báo hệ thống đang bảo trì và tạm thời không truy cập được các chức năng chính. Cơ chế này phù hợp trong trường hợp cần cập nhật dữ liệu, bảo trì hoặc huấn luyện lại mô hình.

3.3. Kiến trúc hệ thống

Hệ thống được thiết kế theo kiến trúc ba lớp kết hợp giữa mô hình client-server và mô hình tích hợp dịch vụ học máy. Kiến trúc này giúp tách biệt rõ ràng phần giao diện, phần xử lý nghiệp vụ và phần trí tuệ nhân tạo, từ đó tăng tính mở rộng, dễ bảo trì và dễ kiểm thử.



Hình 3.1: Kiến trúc tổng thể của hệ thống

Lớp thứ nhất là lớp trình bày, được xây dựng bằng React trên trình duyệt web. Lớp này chịu trách nhiệm hiển thị giao diện cho người dùng và quản trị viên, bao gồm các trang

đăng nhập, trang quản lý vườn cây, nhật ký, chi phí, dự đoán bệnh, thư viện bệnh, trang quản trị và trang huấn luyện mô hình. Giao diện được thiết kế theo hướng tối ưu trải nghiệm người dùng, sử dụng TailwindCSS để đảm bảo bố cục linh hoạt và nhất quán.


Lớp thứ hai là lớp xử lý nghiệp vụ, được xây dựng bằng Node.js và Express. Lớp này tiếp nhận các yêu cầu từ phía giao diện, thực hiện xác thực người dùng, phân quyền, xử lý CRUD, thao tác với dữ liệu MongoDB và điều phối giữa frontend với dịch vụ Machine Learning. Các API trong backend được tổ chức theo từng nhóm chức năng như xác thực, quản lý người dùng, vườn cây, nhật ký, chi phí, dự đoán, bệnh, công việc, mùa vụ và huấn luyện mô hình.

Lớp thứ ba là lớp dữ liệu và trí tuệ nhân tạo. Dữ liệu nghiệp vụ được lưu trữ trong MongoDB dưới dạng các collection. Riêng chức năng dự đoán bệnh được thực hiện bởi một dịch vụ Machine Learning riêng viết bằng Python với Flask, sử dụng TensorFlow để xây dựng và chạy mô hình MobileNetV2. Dịch vụ này nhận ảnh từ backend, xử lý ảnh đầu vào, đưa ảnh qua mô hình đã huấn luyện và trả về kết quả dự đoán. Khi huấn luyện lại mô hình, backend sẽ phối hợp với script Python để cập nhật mô hình và đồng bộ kết quả.

Về mặt tổ chức chức năng, kiến trúc hệ thống có thể mô tả theo hướng sau. Người dùng thao tác trên giao diện web, gửi yêu cầu đến backend qua REST API. Backend xác thực quyền truy cập, xử lý logic nghiệp vụ, truy vấn hoặc cập nhật dữ liệu trong MongoDB, đồng thời trong trường hợp dự đoán bệnh thì chuyển dữ liệu ảnh sang dịch vụ Machine Learning. Dịch vụ Machine Learning nhận ảnh, trả kết quả dự đoán về backend và backend trả dữ liệu cho giao diện để hiển thị cho người dùng. Cách tổ chức này giúp hệ thống tách biệt tương đối độc lập giữa quản lý dữ liệu nghiệp vụ và xử lý trí tuệ nhân tạo.

3.4. Thiết kế dữ liệu

Hệ thống sử dụng cơ sở dữ liệu MongoDB, do đó thiết kế dữ liệu được xây dựng theo mô hình tài liệu. Đây là mô hình phù hợp với dữ liệu có cấu trúc linh hoạt, nhiều thực thể có quan hệ một-nhiều, đồng thời thuận lợi cho việc mở rộng các trường thông tin mới trong tương lai. Mỗi nhóm dữ liệu chính được lưu trong một collection riêng.



Hình 3.2: Sơ đồ ERD của hệ thống

Bảng 3.1: Mô tả các quan hệ giữa các thực thể (collection)

Thực thể (collection)	Thuộc tính chính	Khóa chính	Khóa ngoại	Mối quan hệ
users	id, ho_ten, email, mat_khau, vai_tro, is_locked, ngay_tao	id	-	1-N với gardens, predictions, notification_tracking
seasons	id, ten_mua_vu, nam, thang_bat_dau, thang_ket_thuc, trang_thai, mo_ta, ngay_tao	id	-	1-N với gardens, logs, expenses
gardens	id, user_id, season_id, ten_vuon, dien_tich, don_vi, dia_chi, so_cay, ngay_tao, ngay_cap_nhat	id	user_id, season_id	N-1 với users, seasons; 1-N với plots, logs, expenses
plots	id, garden_id, name, area, tree_type, location_description, status, created_at	id	garden_id	N-1 với gardens; 1- N với logs, notification_tracking
tasks	id, ten_cong_viec, mo_ta, dieu_kien_thuc_hien, ngay_tao	id	-	1-N với logs, notifications
logs	id, garden_id, season_id, notification_id, task_id, plot_id, plot_ids, ngay_lam, ghi_chu, is_completed, nguai_thuc_hien, ngay_tao	id	garden_id, season_id, notification _id, task_id, plot_id	N-1 với gardens, seasons, notifications, tasks, plots

Thực thể (collection)	Thuộc tính chính	Khóa chính	Khóa ngoại	Mối quan hệ
notifications	id, tieu_de, noi_dung, doi_tuong_nhan, nhom_nguoi_nhan, da_doc_boi, link, trang_thai, loai, task_id, ngay_lam, ghi_chu, nhac_nho_cho_notification _id, ngay_tao	id	task_id, nhac_nho_ cho_notific ation_id	N-1 với tasks; tự liên kết 1-N; 1-N với logs, notification_tracking
expenses	id, garden_id, season_id, loai_chi_phi, plot_ids, items, so_tien, ngay, don_vi, ngay_tao, ngay_cap_nhat	id	garden_id, season_id	N-1 với gardens, seasons
predictions	id, user_id, hinh_anh, ket_qua_benh, do_tin_cay, mo_ta_benh, huong_xu_ly, tuvan_ai, grad_cam_path, thoi_gian_xu_ly_ms, ngay_du_doan	id	user_id	N-1 với users
fertilizers	id, ten_phan_bon, mo_ta, thanh_phan, cong_dung, gia_tien, cach_su_dung, don_vi, ngay_tao, ngay_cap_nhat	id	-	N-N với diseases

Thực thể (collection)	Thuộc tính chính	Khóa chính	Khóa ngoại	Mối quan hệ
pesticides	id, ten_thuoc, mo_ta, loai, hoat_chat, gia_tien, cach_su_dung, muc_do_doc_hai, ngay_tao, ngay_cap_nhat	id	-	N-N với diseases
diseases	id, ten_benh, mo_ta, nguyen_nhan, trieu_chung, huong_xu_ly, loai_cay_bi_anh_huong, muc_do_nguy_hiem, ten_benh_en, ngay_tao	id	-	N-N với fertilizers, pesticides

Mối quan hệ:

1-N: Quan hệ One to Many (ví dụ: Một users có nhiều gardens).

N-1: Quan hệ Many to One (ví dụ: Nhiều plots thuộc một gardens).

N-N: Quan hệ Many to Many (ví dụ: Một diseases chứa nhiều fertilizers, một fertilizers có thể xuất hiện trong nhiều diseases).

Quan hệ đặc biệt: notifications tự liên kết (self-reference) (ví dụ: 1 notification có thể nhắc lại notification khác).

Các collection chính bao gồm: người dùng, vườn cây, mùa vụ, nhật ký, chi phí, dự đoán bệnh, bệnh cây, công việc, phân bón và thuốc bảo vệ thực vật. Trong đó, collection người dùng lưu thông tin tài khoản, vai trò, mật khẩu đã mã hóa và trạng thái hoạt động. Collection vườn cây lưu thông tin về tên vườn, diện tích, vị trí và chủ sở hữu. Collection mùa vụ lưu thông tin về mùa canh tác gắn với từng vườn. Collection nhật ký lưu các hoạt động chăm sóc theo thời gian. Collection chi phí lưu các khoản chi phát sinh trong quá trình sản xuất.

Collection dự đoán bệnh lưu lịch sử các lần dự đoán từ ảnh lá cây, bao gồm đường dẫn ảnh, tên bệnh dự đoán, độ tin cậy, thời gian dự đoán và người thực hiện. Collection bệnh là collection quan trọng trong phần thư viện bệnh và phần hỗ trợ huấn luyện mô hình.


Mỗi bản ghi bệnh gồm tên bệnh tiếng Việt, mô tả, nguyên nhân, triệu chứng, hướng xử lý, mức độ nguy hiểm, cây bị ảnh hưởng và tên class tiếng Anh tương ứng để liên kết với bộ dữ liệu Machine Learning. Đây là điểm kết nối giữa hệ thống quản lý nghiệp vụ và mô hình học máy.

Việc sử dụng mô hình tài liệu giúp hệ thống dễ lưu trữ các thuộc tính đa dạng của từng bệnh, ví dụ như danh sách cây bị ảnh hưởng, gợi ý phân bón, gợi ý thuốc và thông tin xử lý. Đồng thời, MongoDB cũng hỗ trợ tốt cho các truy vấn tổng hợp và populate, giúp hiển thị dữ liệu liên kết thuận tiện trên giao diện.

Có thể mô tả ngắn gọn thiết kế dữ liệu theo hướng: mỗi thực thể chính được lưu thành một tài liệu riêng, các quan hệ tham chiếu được biểu diễn bằng ObjectId, còn dữ liệu liên quan nhiều-nhiều được lưu dưới dạng mảng tham chiếu. Cách thiết kế này phù hợp với hệ thống hiện tại vì hệ thống vừa có dữ liệu quản lý nghiệp vụ, vừa có dữ liệu bệnh và dữ liệu huấn luyện AI, có thể thay đổi theo thời gian.

3.5. Thiết kế xử lý


Thiết kế xử lý của hệ thống được xây dựng theo mô hình xử lý theo yêu cầu - phản hồi, kết hợp với một số tiến trình bất đồng bộ đối với tác vụ nặng như huấn luyện lại mô hình. Đây là mô hình phù hợp với ứng dụng web có nhiều thao tác CRUD và có một số chức năng tính toán chuyên sâu.



Hình 3.3: Mô hình xử lý của hệ thống

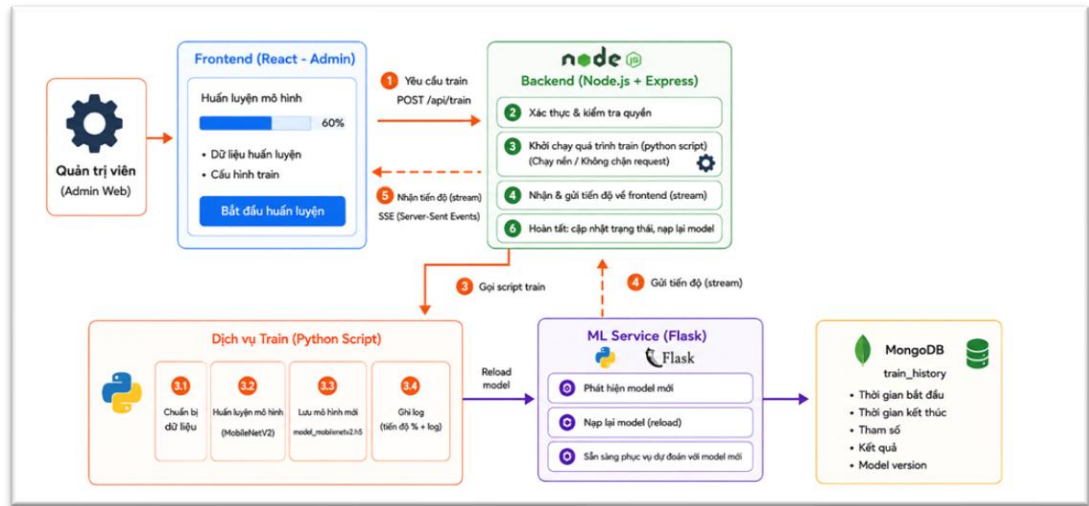
Đối với các chức năng nghiệp vụ thông thường, quy trình xử lý diễn ra theo chuỗi: người dùng thao tác trên giao diện, frontend gửi yêu cầu đến backend, backend kiểm tra

xác thực và phân quyền, sau đó thực hiện xử lý dữ liệu trong cơ sở dữ liệu rồi trả kết quả về cho giao diện. Ví dụ, khi người dùng thêm một vườn cây mới, frontend gửi thông tin vườn lên API, backend kiểm tra token, xác thực quyền của người dùng, lưu dữ liệu vào MongoDB và trả thông báo thành công hoặc thất bại.



Hình 3.4: Quy trình dự đoán bệnh (tích hợp dịch vụ Machine Learning)

Đối với chức năng dự đoán bệnh, quy trình xử lý có thêm bước tích hợp với dịch vụ học máy. Người dùng tải ảnh lá lên, backend nhận ảnh và chuyển ảnh sang dịch vụ Machine Learning. Dịch vụ Machine Learning đọc ảnh, tiền xử lý ảnh, đưa ảnh qua mô hình MobileNetV2 đã huấn luyện, sau đó tính xác suất cho từng lớp bệnh bằng softmax và trả về kết quả dự đoán. Backend nhận kết quả từ Machine Learning, lưu lịch sử và trả kết quả cho frontend để hiển thị. Trong quá trình này, mô hình xử lý vừa mang tính tuần tự vừa mang tính bất đồng bộ, vì việc dự đoán có thể thực hiện độc lập với các chức năng nghiệp vụ khác.



Hình 3.5: Quy trình huấn luyện lại mô hình

Đối với chức năng huấn luyện lại mô hình, hệ thống sử dụng cơ chế xử lý nền. Quản trị viên khởi động quá trình train từ giao diện admin, backend gọi script Python để thực hiện huấn luyện lại mô hình trên dữ liệu mới. Trong khi quá trình train đang chạy, tiến độ được truyền về giao diện thông qua cơ chế streaming, giúp quản trị viên theo dõi trạng thái huấn luyện theo thời gian thực mà không cần chờ trang tải lại. Sau khi huấn luyện hoàn tất, mô hình mới được lưu và dịch vụ dự đoán được nạp lại để sử dụng phiên bản cập nhật.

Nhìn tổng thể, hệ thống xử lý theo mô hình tuần tự cho các tác vụ nghiệp vụ cơ bản và xử lý nền cho các tác vụ nặng. Cách thiết kế này giúp giao diện phản hồi tốt, không bị treo khi thực hiện các thao tác dài, đồng thời bảo đảm việc huấn luyện mô hình có thể diễn ra mà không làm gián đoạn các chức năng quản lý khác.

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU

4.1. Giao diện và chức năng hệ thống

4.1.1. Tổng quan giao diện

Hệ thống được xây dựng dưới dạng ứng dụng web với giao diện thân thiện, dễ sử dụng, hỗ trợ người dùng thao tác nhanh chóng và trực quan. Các thành phần giao diện được tổ chức hợp lý, giúp người dùng dễ dàng làm quen ngay cả khi lần đầu sử dụng hệ thống.



Hình 4.1 Giao diện tổng quan của người dùng

Tại đây, người dùng có thể truy cập nhanh đến các chức năng chính như quản lý vườn cây, nhật ký, chi phí và dự đoán bệnh thông qua thanh điều hướng. Ngoài ra, tại đây còn có các thẻ thông tin tóm tắt để người dùng dễ theo dõi để tăng tính trực quan và có thể dự đoán bệnh nhanh.

Footer nằm ở cuối mỗi trang của giao diện người dùng trong hệ thống, đóng vai trò cung cấp thông tin tổng quan, điều hướng nhanh và thông tin liên hệ. Thiết kế footer được xây dựng với bố cục rõ ràng, chia thành nhiều cột giúp người dùng dễ dàng tìm kiếm thông tin cần thiết.



Hình 4.2: Giao diện Footer của hệ thống

Trong đó:

Phần giới thiệu: hiển thị tên hệ thống (MAP-Citrus) và mô tả ngắn về chức năng hỗ trợ quản lý và dự đoán bệnh.

Phần điều hướng: cung cấp các liên kết nhanh như trang chủ, nhật ký canh tác, thống kê và chẩn đoán AI.

Phần tài liệu: bao gồm hướng dẫn sử dụng, thư viện bệnh và chính sách bảo mật.

Phần liên hệ: hiển thị thông tin người phát triển, email và đơn vị đào tạo.

Ngoài ra, footer còn hiển thị thông tin bản quyền và giảng viên hướng dẫn nhằm đảm bảo tính đầy đủ và chuyên nghiệp cho hệ thống. Thành phần này giúp tăng tính tin cậy và hỗ trợ người dùng trong quá trình sử dụng lâu dài.

4.1.2. Chức năng xác thực

Chức năng xác thực cho phép người dùng đăng nhập tài khoản vào hệ thống. Hệ thống sử dụng cơ chế xác thực bằng token nhằm đảm bảo tính bảo mật và kiểm soát truy cập. Thông tin người dùng được mã hóa và lưu trữ an toàn, hạn chế các rủi ro liên quan đến bảo mật.



Hình 4.3: Giao diện đăng nhập của hệ thống

Trong đó người dùng nhập thông tin tài khoản để truy cập. Sau khi xác thực thành công, hệ thống chuyển hướng đến trang chính tương ứng với quyền của người dùng, đồng thời lưu trạng thái đăng nhập để cải thiện trải nghiệm sử dụng.

4.1.3. Quản lý vườn


Chức năng quản lý vườn cho phép người dùng tạo mới, chỉnh sửa và theo dõi thông tin các vườn cây đang quản lý. Đây là chức năng trung tâm của hệ thống.

MAP Citrus			
Trang chủ Vườn cây Dự đoán Nhật ký Chi phí Thống kê			
Vườn Của Tôi			
Tìm kiếm theo tên vườn hoặc địa chỉ...			
TÊN VƯỜN	ĐỊA CHỈ	DIỆN TÍCH	MÙA VỤ
Vườn của An 01	Hưng Mỹ, Vĩnh Long	10 hectare	Vu Tết 2027 - Dưỡng trái Đang diễn ra
Vườn của An 02	Hưng Mỹ, Vĩnh Long	100 m²	Vu Tết 2027 - Dưỡng trái Đang diễn ra
Vườn của An 03	Hưng Mỹ, Vĩnh Long	100 hectare	Vu Tết 2027 - Dưỡng trái Đang diễn ra

Hình 4.4: Giao diện quản lý vườn

Người dùng có thể xem thông tin chi tiết từng vườn một cách trực quan bằng cách nhấn chọn bất kỳ 1 vườn.

Trang chi tiết vườn cung cấp cái nhìn tổng quan và chi tiết về một vườn cây cụ thể, giúp người dùng theo dõi toàn bộ hoạt động canh tác tại vườn đó. Giao diện được thiết kế theo dạng dashboard với nhiều khối thông tin trực quan, hỗ trợ người dùng nắm bắt nhanh tình trạng hiện tại của vườn.



Hình 4.5: Giao diện chi tiết vườn


Trong cấu trúc giao diện này, các thành phần chính được thiết kế và bố trí một cách trực quan nhằm tối ưu hóa trải nghiệm người dùng. Đầu tiên, thành phần tiến độ thực hiện công việc được hiển thị sinh động dưới dạng các thanh tiến trình (progress bar), giúp phản ánh chính xác số lượng công việc đã hoàn thành so với các hạng mục chưa thực hiện, từ đó hỗ trợ nhà vườn đánh giá nhanh mức độ hoàn thiện các công việc trong phạm vi khu vườn. Song song đó, phần thống kê tổng quan đóng vai trò hợp nhất dữ liệu thông qua việc cung cấp các chỉ số đo lường cốt lõi bao gồm tổng số lượng nhật ký canh tác, tổng chi phí vận hành, số lượng các mẫu đất hiện có và tổng diện tích đang được đưa vào sử dụng.

Đối với danh sách mẫu đất, thành phần này đảm nhiệm việc hiển thị thông tin chi tiết của từng phân vùng cụ thể trong vườn bao gồm tên gọi, diện tích bề mặt, loại cây trồng và mô tả định vị vị trí. Đồng thời, trạng thái thực hiện cùng tình trạng sử dụng đất cũng được thể hiện một cách rõ ràng, cho phép người dùng chủ động tương tác thông qua các thao tác nghiệp vụ cơ bản bao gồm thêm mới, chỉnh sửa thông tin hoặc xóa bỏ mẫu đất khỏi hệ thống quản lý.

Cuối cùng, phân đoạn nhật ký gần đây chịu trách nhiệm liệt kê các hoạt động chăm sóc cây trồng mới nhất như quy trình tưới nước, phun thuốc bảo vệ thực vật hay làm đất, giúp người dùng dễ dàng theo dõi dòng lịch sử canh tác và kiểm tra tính liên tục của các công việc đã thực hiện. Đi kèm với đó, thành phần chi phí gần đây cũng chủ động cung cấp thông tin cập nhật theo thời gian thực về các khoản chi tiêu mới phát sinh, giúp chủ vườn kiểm soát tốt dòng tiền đầu tư một cách chặt chẽ và hiệu quả.

4.1.4. Quản lý chi phí

Chức năng quản lý chi phí giúp người dùng theo dõi các khoản chi trong quá trình chăm sóc và sản xuất, từ đó hỗ trợ quản lý tài chính hiệu quả.



Hình 4.6: Giao diện quản lý chi phí

Trong đó, các khoản chi được thêm mới, sửa hoặc xóa chi phí. Lịch sử chi được hiển thị theo danh sách, khi nhấn chọn bất kỳ sẽ hiển thị chi tiết chi phí giúp người dùng dễ dàng theo dõi và thống kê.

4.1.5. Quản lý nhật ký

Nhật ký là nơi ghi lại các hoạt động chăm sóc cây trồng theo thời gian, giúp người dùng theo dõi quá trình phát triển và đưa ra quyết định phù hợp.

VƯỜN	TÊN MẪU ĐẤT	CÔNG VIỆC	NGƯỜI THỰC HIỆN	NGÀY LÀM	TRẠNG THÁI	THAO TÁC
Vườn của An 01	Cam Xoàn	Tưới nước	Phúc An	14/6/2026	Chưa ☐	Sửa Xóa
Vườn của An 01	Cam sành	Tưới nước	—	14/6/2026	Đã ☒	Sửa Xóa
Vườn của An 02	Mẫu HM 01	Tưới nước	—	14/6/2026	Đã ☒	Sửa Xóa
Vườn của An 03	Cam HH01	Tưới nước	—	14/6/2026	Đã ☒	Sửa Xóa
Vườn của An 03	Cam HH 02	Tưới nước	—	14/6/2026	Đã ☒	Sửa Xóa


Hình 4.7: Giao diện nhật ký

Cho phép người dùng thêm mới các hoạt động như tưới nước, bón phân hoặc xử lý bệnh... và xác nhận đã làm, đồng thời xem lại lịch sử hoạt động.

4.1.6. Dự đoán bệnh

Chức năng hỗ trợ dự đoán dịch bệnh qua hình ảnh được định vị là phân hệ cốt lõi và nổi bật nhất của toàn hệ thống, cho phép người dùng chủ động tải lên các hình ảnh lá cây thực địa để nhận về kết quả chẩn đoán tự động từ mô hình học máy. Giao diện của phân hệ này được thiết kế thành các phân vùng chức năng rõ ràng, không chỉ hiển thị kết quả phân loại đơn thuần mà còn hỗ trợ mạnh mẽ cơ chế giải thích mô hình một cách trực quan.

Quy trình vận hành tác vụ dự đoán được tối ưu hóa theo một luồng xử lý khép kín và tiện lợi. Ngay sau khi người dùng cung cấp ảnh chụp lá cây cam, hệ thống sẽ lập tức tính toán và trả về danh sách ba kết quả có khả năng xảy ra cao nhất đi kèm với phân bố xác suất tương ứng. Tại đây, người dùng có thể linh hoạt lựa chọn một trong các kết quả chẩn đoán để hệ thống kích hoạt tính năng tư vấn bệnh, đưa ra các giải pháp can thiệp khoa học. Bên cạnh đó, hệ thống còn tích hợp bản đồ nhiệt Grad-CAM giúp trực quan hóa chính xác phân vùng ảnh mà mô hình đã tập trung khai thác đặc trưng khi đưa ra quyết định, đồng thời tự động đồng bộ hóa dữ liệu vào luồng lịch sử dự đoán của cá nhân.




Hình 4.8: Giao diện dự đoán bệnh

Bố cục giao diện của chức năng này được sắp xếp khoa học theo mô hình đa tầng trực quan. Tại khu vực phía trên bên trái, hệ thống bố trí vùng tương tác để người dùng tải ảnh

đầu vào và hiển thị lớp phủ bản đồ nhiệt Grad-CAM sau khi xử lý. Đối ứng trực tiếp ở phía trên bên phải là phân vùng hiển thị danh sách các lớp bệnh được dự đoán, tỷ lệ phần trăm độ tin tưởng tương thích cùng hộp thoại đưa ra lời tư vấn kỹ thuật từ AI. Di chuyển xuống khu vực phía dưới, không gian giao diện được phân bổ cho bảng danh sách lịch sử các lần dự đoán trước đó, đặt ngay cạnh phân hệ hiển thị chi tiết của chính bản ghi dự đoán được lựa chọn ở phía bên phải, tạo nên một tổng thể quản lý thông tin liền mạch và nhất quán.

4.1.7. Thư viện bệnh


Thư viện bệnh cung cấp thông tin chi tiết về các loại bệnh trên cây, giúp người dùng nhận biết và xử lý kịp thời. Đây là nguồn tài liệu ban đầu để dựa vào mà dự đoán. Thông tin trong thư viện bao gồm hình ảnh minh họa và mô tả cụ thể về triệu chứng, nguyên nhân và cách phòng trị. Trang này được đặt liên kết ở thanh footer của giao diện.



Hình 4.9: Giao diện thư viện bệnh

4.1.8. Một số chức năng quản trị

4.1.8.1. Xem tổng quan hệ thống




Hình 4.10: Thanh menu và giao diện tổng quan của người quản trị

Tại đây, quản trị viên có thể lựa chọn từng menu tương ứng với các chức năng của admin. Ngoài ra, còn có chức năng đổi mật khẩu và đăng xuất. Với giao diện “Tổng quan”, cho phép xem nhanh tổng quan các chỉ số quan trọng của dự án và hỗ trợ quản trị viên theo dõi hoạt động người dùng và tình trạng dữ liệu một cách hiệu quả.

4.1.8.2. Chức năng quản lý bệnh

Quản trị viên có thể thêm, chỉnh sửa hoặc xóa thông tin bệnh nhằm cập nhật dữ liệu cho hệ thống và phục vụ huấn luyện mô hình (ban đầu, mặc định có 8 bệnh, sau đó người quản trị có thể thêm các bệnh khác).




TÊN BỆNH (VI)	TÊN BỆNH (EN)	MỨC ĐỘ NGUY HIỂM	THAO TÁC
* Bệnh hỗn hợp	multiple	Cao	Sửa Xóa
* Bệnh loét hại cây có múi	canker	Cao	Sửa Xóa
* Bệnh vàng lá gân xanh	greening	Cao	Sửa Xóa
* Bệnh dóm dầu	greasy_spot	Cao	Sửa Xóa
* Bệnh dóm đen	black_spot	Trung bình	Sửa Xóa
* Khỏe mạnh	healthy	Không	Sửa Xóa
* Sâu vẽ bùa	leafminer	Trung bình	Sửa Xóa
* Sâu ăn lá	Leaf_eating_worm	Trung bình	Sửa Xóa
* Thiếu dinh dưỡng	deficiency	Trung bình	Sửa Xóa
* Xoắn lá	Citrus_Leaf_Curl	Cao	Sửa Xóa

Hình 4.11: Giao diện quản lý bệnh

4.1.8.3. Chức năng quản lý nhật ký bệnh

Chức năng này cho phép quản trị viên theo dõi lịch sử các lần dự đoán của người dùng, cũng như thống kê sự phân bố bệnh phát sinh theo tháng.




Hình 4.12: Giao diện hiển thị danh sách các kết quả dự đoán

4.1.8.4. Chức năng quản lý nhật ký canh tác


Quản trị viên có thể giám sát các hoạt động được ghi nhận trong hệ thống.



Hình 4.13: Giao diện quản lý nhật ký ở cấp “Mùa vụ”.



Hình 4.14: Giao diện quản lý nhật ký cấp “Vườn”



Hình 4.15: Giao diện chi tiết quản lý nhật ký theo vườn

4.1.8.5. Chức năng quản lý chi phí

Cho phép quản trị viên kiểm tra và tổng hợp chi phí theo mùa vụ của từng người dùng trong hệ thống.

Xem Chi Phí

Danh sách Mùa Vụ

Vụ Tết 2027 - Dưỡng trái Năm: 2026 Tổng chi phí: 4.750.000 đ Dang diễn ra	Vụ Tết 2027 - Kích hoa Năm: 2026 Tổng chi phí: 4.700.000 đ Đã kết thúc	Vụ Tết 2027 - Phục hồi Năm: 2026 Tổng chi phí: 0 đ Đã kết thúc
--	---	---

Hình 4.16: Giao diện quản lý chi phí cấp “Mùa vụ”

Xem Chi Phí

Danh sách Người dùng - Vụ Tết 2027 - Dưỡng trái (2026)
Xem người dùng dưới dạng bảng và tìm nhanh theo tên hoặc email.

Phúc An 1 người dùng

NGƯỜI DÙNG	EMAIL	SỐ VƯỜN	TỔNG CHI PHÍ
Phúc An	phucan@gmail.com	3	1.250.000 đ

Hình 4.17: Giao diện quản lý chi phí cấp “Người dùng”

Xem Chi Phí

Danh sách Vườn - Phúc An
Xem danh sách vườn dưới dạng bảng và tìm nhanh theo tên vườn hoặc địa điểm.

Tìm theo tên vườn hoặc địa điểm... 2 vườn

TÊN VƯỜN	ĐỊA CHỈ	SỐ CHI PHÍ	TỔNG CHI PHÍ
Vườn của An 01	Hung Mỹ, Vĩnh Long	1	1.250.000 đ
Vườn của An 02	Hung mỹ, Vĩnh Long	1	1.256.000 đ

Hình 4.18: Giao diện quản lý chi phí cấp “Vườn”

Xem Chi Phí

← Chi Phí - Vườn của An 01

Xem danh sách khoản chi và chi tiết từng mục hàng.

Số khoản chi

1

Tổng chi phí

1.250.000 đ

Chi phí đang xem

Điện nước

Danh sách chi phí

Chọn một dòng để xem chi tiết mặt hàng ở khung bên phải

1 bản ghi

Điện nước	16/5/2026	1.250.000 đ
Vườn của An 01		1 mặt hàng

CHI TIẾT CHI PHÍ

Điện nước

16/5/2026 · 1 mặt hàng

tiền điện

Số lượng	Đơn giá
1 tháng	1.250.000 đ
Tổng tiền	
1.250.000 đ	

Tổng chi phí

1.250.000 đ

Hình 4.19: Giao diện chi tiết quản lý chi phí theo vườn

4.1.8.6. Chức năng quản lý thông báo và kiểm soát hoạt động

Chức năng này hỗ trợ gửi thông báo và giám sát hoạt động của người dùng nhằm đảm bảo người quản trị biết trực tiếp tình trạng của vườn.

Quản Lý Thông Báo

+ Tạo thông báo

Thông báo bình thường

Thông báo Kiểm soát

Tìm kiếm theo tiêu đề, nội dung hoặc đối tượng nhận...

Tiêu đề	Nội dung	Đối tượng	Trạng thái	Ngày tạo	Thao tác
Nhắc nhở: Xiết cảnh ra bóng	Đề nghị bà con thực hiện thông báo này	Nhóm: Anh Thư, Gia Huy, Hữu Luân, P	active	15:12:21 16/5/2026	Sửa Xóa
Nhắc nhở: Nhắc nhở xịt thuốc	Thuốc ABC	Nhóm: Phúc An	active	12:59:56 23/5/2026	Sửa Xóa
Thông báo lịch bảo trì hệ thống	Thời gian từ 14:00 ngày 20/5/2026 đến 17:00 ngày 20/5/2026	Tất cả user	active	12:23:27 20/5/2026	Sửa Xóa

Hình 4.20: Giao diện quản lý thông báo bình thường

Ngoài ra, còn có chức năng quản lý kiểm soát hoạt động của vườn. Tại đây, quản trị viên có thể tạo thông báo kiểm soát Ví dụ: Quản trị viên tạo thông báo “Nhắc nhở xịt thuốc” và gửi đến cho tất cả người dùng. Đồng thời, hệ thống sẽ tự động tạo nhật ký công việc cho tất cả người dùng và mặc định là chưa làm. Người dùng cần cập nhập lại để đánh dấu là “Đã làm”. Từ đó, quản trị viên có thể kiểm soát được mỗi vườn.

Quản Lý Thông Báo

+ Tạo thông báo

Thông báo bình thường

Thông báo Kiểm soát

Tìm kiếm theo tiêu đề, nội dung hoặc đối tượng nhận...

Tiêu đề	Ghi chú	Đối tượng	Trạng thái	Ngày tạo	Thao tác
Xiết cánh ra bông Công việc: Cắt định cây (chống đổ) Ngày: 17/5/2025	Cố định cây chống bão	Tất cả user	active	15 10 48 16/6/2025	Sửa Xóa
Tưới nước Công việc: Tưới nước Ngày: 14/5/2025	Tưới nước toàn diện	Tất cả user	active	11 19 32 13/6/2025	Sửa Xóa
Nhắc nhở xịt thuốc Công việc: Xịt thuốc Ngày: 23/5/2025	Thuốc ABC	Tất cả user	active	08 25 54 22/5/2025	Sửa Xóa

Hình 4.21: Giao diện quản lý thông báo kiểm soát

Chi tiết thông báo kiểm soát		Đóng
Nhắc nhở xịt thuốc		
Đã làm		3
Phúc An Vườn của An 03 · Cam HH 02		Đã làm
Phúc An Vườn của An 03 · Cam HH01		Đã làm
Phúc An Vườn của An 02 · Mẫu HM 01		Đã làm
Chưa làm		2
Phúc An Vườn của An 01 · Cam sành		Chưa làm
Phúc An Vườn của An 01 · Cam Xoàn		Chưa làm
Nhắc nhở các user chưa làm		

Hình 4.22: Giao diện chức năng kiểm soát vườn từ thông báo kiểm soát

4.1.8.7. Chức năng quản lý phân bón và thuốc

Chức năng quản lý phân bón và thuốc giúp người dùng theo dõi, lưu trữ và kiểm soát việc sử dụng các loại vật tư nông nghiệp trong quá trình canh tác. Hệ thống cho phép người dùng thêm mới, chỉnh sửa và xóa thông tin về các loại phân bón và thuốc bảo vệ thực vật, bao gồm các thuộc tính như tên, thành phần, giá tiền, công dụng, đơn vị...

Quản Lý Phân Bón						+ Thêm Phân Bón Mới
Search by fertilizer name...						
TÊN PHÂN BÓN	THÀNH PHẦN	GIÁ TIỀN	CÔNG DỤNG	ĐƠN VỊ	THAO TÁC	
Bón Lá Super Acid Humic Hợp Trí (1kg)	Acid Humic 70%. Độ ẩm: 20%	124.000 ₫	Khi phun · Tăng cường các hoạt động sinh tổng hợp...	túi	Sửa	Xóa
Canxi Bo GREENRICE - 100ml	Bo: 10.000 ppm, Ca: 5%, pH: 5. Tỷ trọng: 1.1...	25.000 ₫	Giúp cánh hoa phát triển, không bị gãy. Giúp hạn ch...	chai	Sửa	Xóa
Canxi Nitrat - Ca(NO3)2 - Gói 1kg	Nts: 15%, CaO: 26% Độ ẩm: 1%	50.000 ₫	Tăng cường chất đạm và Canxi dạng dễ tiêu giúp c...	túi	Sửa	Xóa
Kali bột MOP Phú Mỹ (Bao 50kg)	K2O: 61% Độ ẩm: ≤ 0.5%	1.190.000 ₫	Giúp cây cứng, chịu rét, giảm lốp đổ, sâu bệnh, nả...	bao	Sửa	Xóa

Hình 4.23: Giao diện quản lý phân bón

Quản Lý Thuốc					
Thêm Thuốc Mới Search by pesticide name...					
TÊN THUỐC	LOẠI	HOẠT CHẤT	GIÁ TIỀN	ĐỘC HẠI	THAO TÁC
Actara 25WG (1g)	Trừ sâu	Thiamethoxam 250g/kg. Phụ gia: 750g/kg	8.200 đ	Trung bình	Sửa Xóa
Alette 800WG (100g)	Trừ bệnh	Fosetyl Aluminium: 800g/kg. Phụ gia: 200g/kg	64.000 đ	Thấp	Sửa Xóa
Champion 77WP (100g)	Trừ bệnh	Copper Hydroxide 77% w/w, phụ gia.	40.000 đ	Thấp	Sửa Xóa
Confidor 200SL – Chai 100ml	Trừ bệnh	Imidacloprid 200g/L. Phụ gia: 800g/L	129.000 đ	Trung bình	Sửa Xóa

Hình 4.24: Giao diện quản lý thuốc


Ngoài ra, chức năng này còn hỗ trợ liên kết với nhật ký canh tác, giúp ghi nhận chi tiết các lần sử dụng phân bón và thuốc trên từng khu vực hoặc mẫu đất cụ thể. Nhờ đó, người dùng có thể dễ dàng theo dõi lịch sử sử dụng, đánh giá hiệu quả và tối ưu hóa quy trình chăm sóc cây trồng.

4.1.8.8. Chức năng đào tạo lại ML và bậc bảo trì hệ thống

Chức năng này cho phép quản trị viên thực hiện huấn luyện lại mô hình học máy và theo dõi toàn bộ quá trình thông qua giao diện trực quan. Hệ thống hiển thị trạng thái hoạt động hiện tại (đang hoạt động hoặc bảo trì), cùng với các thống kê dữ liệu như số lượng lớp bệnh, tổng số ảnh huấn luyện và số ảnh mới được cập nhật.

Trong quá trình huấn luyện, hệ thống cung cấp các chỉ số quan trọng như Accuracy, Loss trên tập train và validation, giúp đánh giá hiệu quả mô hình theo từng lần huấn luyện. Ngoài ra, các chỉ số đánh giá như Precision, Recall và F1-score cũng được hiển thị rõ ràng cho cả tập validation và tập test, hỗ trợ quản trị viên kiểm tra khả năng tổng quát của mô hình.

Bên cạnh đó, hệ thống còn cho phép quản trị viên tải thêm dữ liệu ảnh cho từng loại bệnh nhằm cải thiện độ chính xác của mô hình. Đồng thời, chức năng bật/tắt chế độ bảo trì giúp tạm thời ngăn người dùng truy cập hệ thống trong quá trình huấn luyện hoặc nâng cấp, đảm bảo tính ổn định và an toàn cho hệ thống.



Hình 4.25: Giao diện chức năng huấn luyện mô hình và bảo trì hệ thống

4.2. Kết quả huấn luyện mô hình

4.2.1. Mô tả dữ liệu huấn luyện

Dữ liệu dùng để huấn luyện mô hình dự đoán bệnh trên cây có múi được thu thập từ nhiều nguồn, bao gồm ảnh chụp thực tế tại vườn và các bộ dữ liệu công khai. Tập ảnh bao gồm lá và quả của cây thuộc nhiều loại bệnh như: loét, vàng lá gân xanh, đốm đen, đốm dầu, sâu vẽ bùa.... Tổng số lượng ảnh tổng cộng gồm 13,202 ảnh, tất cả đều được phân loại và gán nhãn chính xác vào các lớp tương ứng theo loại bệnh.

Trước khi huấn luyện, bộ dữ liệu được phân chia thành ba tập độc lập (Train, Validation, Test) theo phương pháp chia ngẫu nhiên có kiểm soát nhằm đảm bảo tính khách quan và nhất quán của dữ liệu thực nghiệm.

Bảng 4.1: Phân chia số lượng ảnh theo ba tập Train/Validation/Test

Tập dữ liệu	Số ảnh	Tỷ lệ	Vai trò
Tập huấn luyện (Train)	10562	~80%	Cập nhật trọng số của các lớp phân loại qua từng epoch.
Tập xác thực (Validation)	1320	~10%	Theo dõi hiệu năng (Precision, Recall, F1-score).
Tập kiểm thử (Test)	1320	~10%	Đánh giá độc lập khả năng tổng quát hóa cuối cùng của mô hình trên dữ liệu thực tế chưa từng thấy.

Phân chia 80/10/10 giúp giữ lại một tập kiểm thử độc lập để đánh giá tổng quát hóa cuối cùng, đồng thời có đủ dữ liệu cho huấn luyện. Tập kiểm thử được tách ra hoàn toàn và lưu trữ riêng biệt trong thư mục “split_dataset” trước khi quá trình huấn luyện bắt đầu. Tập dữ liệu này hoàn toàn không tham gia vào quá trình của mô hình, đảm bảo kết quả đánh giá phản ánh chính xác năng lực nhận diện bệnh của hệ thống khi triển khai thực tế.

4.2.2. Cấu hình huấn luyện

Mô hình học sâu MobileNetV2 được huấn luyện theo chiến lược học chuyển giao (Transfer Learning) nhằm tận dụng mạng xương sống (Backbone) đã được tối ưu hóa các đặc trưng hình ảnh từ tập dữ liệu quy mô lớn ImageNet, giúp mô hình thích nghi nhanh

chóng và hiệu quả với bài toán nhận diện bệnh trên lá hoặc quả của cây cam. Các thông số cấu hình và tham số huấn luyện được trình bày trong bảng dưới đây:

Bảng 4.2: Cấu hình và tham số huấn luyện mô hình MobileNetV2

Tham số	Giá trị
Mô hình	MobileNetV2
Kích thước ảnh đầu vào	224 x 224
Optimizer	Adam
Loss function	Categorical Crossentropy
Batch Size	32
Learning Rate	0.001
Epochs	10
Dropout	0.5
Lớp Phân loại tùy chỉnh (Head)	GlobalAveragePooling2D + Dense + Dropout

Quá trình huấn luyện mô hình MobileNetV2 được thực hiện bằng phương thức học chuyển giao (Transfer Learning) nhằm tận dụng các đặc trưng hình ảnh phong phú đã được học từ tập dữ liệu ImageNet quy mô lớn. Trong quá trình này, toàn bộ các lớp trích xuất đặc trưng của mạng xương sống (backbone) MobileNetV2 được đóng băng trọng số (trainable = False), hệ thống chỉ tập trung huấn luyện phần phân loại tùy chỉnh được thêm vào phía sau bao gồm lớp Pooling toàn cục, lớp ẩn và lớp đầu ra để mô hình nhanh chóng thích nghi và nhận diện chính xác các lớp bệnh trên lá hoặc quả của cây cam.

Để nâng cao khả năng tổng quát hóa và giảm hiện tượng quá khớp, dữ liệu huấn luyện được tăng cường thông qua các phép biến đổi ngẫu nhiên theo thời gian thực như lật ảnh theo chiều ngang, xoay ảnh ngẫu nhiên góc $\pm 20^\circ$, dịch chuyển chiều rộng và chiều cao tối đa 20%, cùng kỹ thuật thu phóng ảnh ngẫu nhiên. Đồng thời, do số lượng mẫu giữa các nhóm bệnh có sự chênh lệch, kỹ thuật cân bằng trọng số lớp (Class Weights) được áp dụng tự động dựa trên số lượng mẫu của từng phân lớp trong thư mục huấn luyện nhằm giảm thiểu ảnh hưởng của sự mất cân bằng dữ liệu, giúp mô hình không bị thiên vị và phạt nặng hơn các lỗi sai ở những nhóm bệnh ít mẫu.

Quá trình huấn luyện tải dữ liệu theo từng lô từ đĩa thông qua trình tạo ảnh để tối ưu bộ nhớ và ghi nhận tiến trình lịch sử một cách chi tiết. Sau khi hoàn tất 10 epochs, hệ thống tiến hành đánh giá toàn diện hiệu năng của mô hình thông qua việc tính toán các chỉ số nâng cao như Precision, Recall, F1-score trên cả tập xác thực nội bộ và tập kiểm thử độc lập, sau đó tự động xuất các file báo cáo lịch sử và ảnh xạ nhãn phục vụ cho việc tích hợp vào hệ thống quản lý vườn cam.

4.2.3. Kết quả huấn luyện

Sau quá trình huấn luyện với cấu hình trên, mô hình thu được các quan sát sau (ví dụ minh họa giá trị thực tế lấy từ huấn luyện của dự án):

Bảng 4.3: Kết quả sau khi huấn luyện mô hình

Chỉ số	Kết quả
Training Accuracy (Độ chính xác của mô hình trên tập huấn luyện)	92.46%
Validation Accuracy (Độ chính xác trên tập xác thực)	94.85%
Training Loss (Sai số trên tập huấn luyện)	0.2124
Validation Loss (Sai số trên tập xác thực)	0.1496

Kết quả huấn luyện cho thấy mô hình đạt hiệu suất cao và ổn định. Cụ thể, độ chính xác trên tập huấn luyện đạt 92.46%, trong khi trên tập kiểm định đạt 94.85%. Việc độ chính xác trên tập validation cao hơn tập train cho thấy mô hình không có dấu hiệu bị quá khớp (overfitting).

Giá trị hàm mất mát (loss) cũng phản ánh xu hướng tích cực khi $\text{train loss} = 0.2124$ và $\text{validation loss} = 0.1496$, trong đó loss trên tập validation thấp hơn tập huấn luyện. Điều này cho thấy mô hình học được các đặc trưng có ý nghĩa và không bị học thuộc dữ liệu.

Nhìn nhận một cách chuyên sâu, mô hình thể hiện năng lực phân biệt vượt trội đối với các phân lớp bệnh sở hữu dấu hiệu hình thái học rõ ràng, điển hình như loét hay các đường gợn dạng uốn khúc đặc trưng của sâu vẽ bùa. Dù vậy, tại một số phân lớp có biểu hiện lâm sàng tương đồng hoặc có dung lượng mẫu vật còn hạn chế, hệ thống vẫn ghi nhận tỷ lệ nhầm lẫn cục bộ, làm ảnh hưởng nhẹ đến hiệu suất tổng thể của riêng các nhóm bệnh hiểm này.

4.2.4. Đánh giá mô hình

Mô hình được đánh giá trên tập test độc lập (10% dữ liệu) với 1320 ảnh:

Bảng 4.4: Kết quả Accuracy, Precision, Recall, F1-Score trên tập test

Chỉ số	Weighted	Macro
Accuracy	94.86%	-
Precision	95.24%	92.39%
Recall	94.86%	92.76%
F1-Score	94.94%	92.41%

Kết quả đánh giá trên tập test cho thấy mô hình đạt hiệu suất cao với độ chính xác tổng thể đạt 94.86%. Các chỉ số trung bình có trọng số (Weighted) như Precision (95.24%), Recall (94.86%) và F1-score (94.94%) đều ở mức tốt, phản ánh khả năng dự đoán hiệu quả trên toàn bộ tập dữ liệu.

Khi xét theo trung bình Macro để đánh giá bình đẳng giữa các lớp, các chỉ số có xu hướng giảm nhẹ nhưng vẫn duy trì ở mức tối ưu, cụ thể Precision đạt 92.39%, Recall đạt 92.76% và F1-score đạt 92.41%. Sự chênh lệch nhỏ chỉ khoảng 2-3% giữa hai phương pháp Weighted và Macro cho thấy mô hình không chỉ học tốt trên các lớp phổ biến có số lượng mẫu lớn, mà còn đạt được sự cân bằng đáng kể và nhận diện hiệu quả trên cả các lớp thiểu số.

Nhìn chung, hệ thống đạt hiệu năng vận hành cực kỳ mạnh mẽ đối với các nhóm bệnh sở hữu số lượng ảnh huấn luyện phong phú, trong khi các lớp bệnh hiếm hoặc có triệu chứng ban đầu gần giống nhau vẫn dễ rơi vào vùng nhận diện sai lệch. Tuy nhiên, kết quả tổng thể thu được cho thấy hệ thống hoàn toàn đủ điều kiện kỹ thuật để triển khai như một công cụ hỗ trợ chẩn đoán bệnh tự động đáng tin cậy, đi kèm với các cơ chế đưa ra cảnh báo đối với những ca dự đoán có độ bất định cao.

Mặc dù vậy, nghiên cứu vẫn còn một số mặt hạn chế nhất định khi nguồn tư liệu ảnh hiện tại chưa đạt đến quy mô lớn và tính đa dạng tối đa để bao quát toàn bộ các biến thể tự nhiên như sự thay đổi ánh sáng, góc chụp hay hiện trạng sinh lý của cây ngoài đời thực. Đồng thời, độ chính xác của mô hình vẫn còn chịu sự chi phối nhất định bởi chất lượng ảnh đầu vào (như độ nhiễu hay độ mờ nhòe) và sự phân bố chưa đồng đều giữa các lớp.

4.3. Demo kết quả Grad-CAM

Grad-CAM là kỹ thuật trực quan hóa cho biết mô hình học sâu tập trung vào vùng ảnh nào khi đưa ra dự đoán. Trong đồ án này, Grad-CAM được áp dụng cho ảnh lá hoặc quả thuộc nhiều lớp bệnh khác nhau; các heatmap được chồng lên ảnh gốc để dễ quan sát.

Giải thích màu:

Đỏ: vùng kích hoạt mạnh nhất (mô hình chú ý nhiều nhất).

Vàng/Cam: mức độ chú ý trung bình.


Xanh: ít ảnh hưởng tới quyết định.

Ví dụ minh họa:

Ví dụ 1 - Bệnh loét (Citrus Canker): heatmap tập trung vào các đốm tròn màu nâu trên lá, trùng hợp với vùng tổn thương điển hình.



Ảnh gốc



Ảnh Card-CAM

Hình 4.26: Ví dụ ảnh Card-CAM bệnh loét

Ví dụ 2 - Vàng lá gân xanh (HLB): heatmap chú ý vào vùng gân lá và các mảng vàng.



Ảnh gốc



Ảnh Card-CAM

Hình 4.27: Ví dụ ảnh Card-CAM bệnh vàng lá gân xanh

Ví dụ 3 - Đốm đen: heatmap bật mạnh ở những chấm đen do bệnh gây ra.



Ảnh gốc



Ảnh Card-CAM

Hình 4.28: Ví dụ ảnh Card-CAM bệnh đốm đen

Những hình ảnh Grad-CAM này cho thấy mô hình không chỉ trả về nhãn mà còn xác định được vùng đặc trưng trên lá, giúp kiểm chứng trực quan cho kết quả dự đoán. Trong dự án, kết quả heatmap được trả về API để frontend hiển thị overlay trên ảnh gốc.

4.4. Đánh giá hệ thống

Để đánh giá hiệu quả của mô hình đề xuất, kết quả thực nghiệm của đề tài được đối chiếu với một số nghiên cứu trong và ngoài nước. Việc so sánh được thực hiện dựa trên phương pháp sử dụng, bộ dữ liệu, số lớp phân loại và các chỉ số đánh giá chính.

Cụ thể, đối với các nghiên cứu quốc tế, phương pháp Deep CNN sử dụng Caffe Framework trên bộ dữ liệu tự thu thập từ Internet (8.741 ảnh, 13 lớp) của Sladojevic và cộng sự đạt độ chính xác từ 91% đến 98% [32]. Nghiên cứu của Ferentinos áp dụng kỹ thuật học chuyển giao (Transfer Learning) với các kiến trúc VGG, AlexNet, GoogLeNet, ResNet trên bộ dữ liệu PlantVillage mở rộng (87.848 ảnh, 58 lớp) đạt độ chính xác rất cao là 99,53% [18]. Trong khi đó, kiến trúc MobileNets dựa trên Depthwise Separable Convolution tối ưu cho thiết bị di động của Howard và cộng sự khi thử nghiệm trên bộ dữ liệu vật thể tổng quát ImageNet (1.000 lớp) đạt độ chính xác Top-1 là 70,6% [22]. Một nghiên cứu khác của Hughes và Salathe sử dụng Deep CNN (AlexNet, GoogLeNet) trên bộ dữ liệu PlantVillage (54.306 ảnh, 38 lớp) cho kết quả độ chính xác đạt 99,35% [23]. Đối với nghiên cứu trong nước, Nguyễn Hồng Quyền và cộng sự đã áp dụng mạng CNN truyền thống trên bộ dữ liệu tự thu thập tại khu vực Đồng bằng sông Cửu Long (1.200 ảnh, 3 lớp) và đạt độ chính xác trên 85% [11]. Trong khi đó, đề tài đề xuất (2026) sử dụng giải pháp học chuyển giao với kiến trúc MobileNetV2 kết hợp Grad-CAM, thực nghiệm trên bộ dữ liệu hợp nhất 5 dataset từ Kaggle và Internet (13.202 ảnh, 10 lớp phân loại) đạt độ

chính xác tập kiểm thử (Test Accuracy) là 94.86%, đi kèm chỉ số F1-score tổng thể đạt 94.94%.

Các nghiên cứu trước đây đã áp dụng nhiều phương pháp khác nhau cho bài toán nhận diện bệnh hại cây trồng, từ các cấu trúc mạng CNN truyền thống đến các mô hình học sâu hiện đại dựa trên kỹ thuật học chuyển giao như VGG, AlexNet, ResNet và kiến trúc tối ưu hóa MobileNets. Kết quả độ chính xác đạt được dao động từ mức trên 85% đến 99,53% tùy theo phương pháp cấu trúc, số lớp bệnh phân loại và điều kiện xây dựng bộ dữ liệu sử dụng.

So với nghiên cứu trong nước của Nguyễn Hồng Quyền và cộng sự [11], đề tài đạt độ chính xác 94.86% trên bộ dữ liệu hợp nhất 13.202 ảnh với 10 lớp phân loại, vượt trội hơn hẳn mức độ chính xác của nghiên cứu tiền nhiệm ($>85\%$ cho 3 lớp bệnh tại ĐBSCL). Sự cải tiến này chứng minh rằng dù bài toán của đề tài có số lượng lớp bệnh phức tạp hơn đáng kể (10 lớp bao gồm các loại bệnh phổ biến trên cây cam), mô hình đề xuất vẫn giữ được độ chính xác và tính ổn định cao.

So với các nghiên cứu quốc tế, độ chính xác của đề tài nằm trong phân khúc cạnh tranh cao, tiệm cận với kết quả của Sladojevic và cộng sự (91% - 98%) [32] và chỉ thấp hơn một chút so với Hughes và Salathe [23] hay Ferentinos [18]. Tuy nhiên, cần lưu ý rằng các nghiên cứu quốc tế kể trên chủ yếu sử dụng bộ dữ liệu chuẩn hóa PlantVillage hoặc ảnh thu thập từ Internet với điều kiện chụp lý tưởng trong phòng thí nghiệm, phong nền đơn sắc và đồng nhất. Việc mô hình đề tài đạt tới 94.86% trên tập dữ liệu hợp nhất thực địa phức tạp (chứa nhiều nhiều môi trường, ánh sáng tự nhiên thay đổi biến động và góc chụp đa dạng ngoài nhà vườn) phản ánh một kết quả khách quan, có khả năng chống nhiễu và thích nghi thực tế rất cao. Đặc biệt, chỉ số Macro F1-score đạt 92.41% khẳng định độ ổn định của mô hình trên toàn bộ các lớp phân loại, không bị hiện tượng học lệch sang các lớp phổ biến. Mặt khác, so với nghiên cứu gốc của Howard và cộng sự [22], việc đề tài ứng dụng biến thể nâng tiến MobileNetV2 kết hợp Grad-CAM đã chứng minh sự tối ưu vượt trội khi vừa đảm bảo hệ thống có dung lượng nhẹ, tốc độ suy luận nhanh phù hợp thiết bị di động, vừa mang lại hiệu năng chính xác vượt bậc so với bản gốc của kiến trúc.

Phần lớn các nghiên cứu trong phần so sánh đối chứng đều tập trung thuần túy vào bài toán thị giác máy tính với đầu vào là ảnh lá cây, đầu ra là tên nhãn bệnh lý, chưa có sự

tối ưu giải thích và hoàn toàn chưa được tích hợp vào một hệ thống quản lý nông nghiệp số phục vụ thực địa. Đề tài sở hữu ba điểm nổi bật và khác biệt cốt lõi so với các nghiên cứu liên quan:

Thứ nhất, nhận diện được 10 lớp bao gồm 9 lớp bệnh hại phổ biến trên cây cam và 1 lớp khỏe mạnh trên bộ dữ liệu hợp nhất thực địa phức tạp với độ chính xác đạt 94.86%, đồng thời tích hợp kỹ thuật Grad-CAM giúp trực quan hóa vùng chú ý thị giác (Heatmap) nhằm giải thích minh bạch quyết định phân loại của mô hình.

Thứ hai, tích hợp mô hình nhận diện vào hệ thống web quản lý hoàn chỉnh, hỗ trợ quản lý thành viên hợp tác xã, thông tin mùa vụ, chi phí, nhật ký canh tác và lưu trữ nhật ký bệnh trạng của từng vườn cây.

Thứ ba, hệ thống tích hợp sẵn phân hệ quản trị nâng cao dành cho Admin, cho phép người quản lý chủ động kích hoạt tiến trình đào tạo lại mô hình (Retraining) trực tiếp trên giao diện khi cập nhật hoặc mở rộng bộ dữ liệu mới, đảm bảo khả năng tự bảo trì và vận hành lâu dài của hệ thống mà không cần can thiệp sâu vào mã nguồn.

4.5. Thảo luận

4.5.1. Cơ chế tái huấn luyện (Retraining) từ dữ liệu người dùng đóng góp

Trong quá trình vận hành thực tế, hệ thống cho phép người dùng (chủ vườn, chuyên gia) tải ảnh lên để dự đoán bệnh. Những hình ảnh thực địa này là nguồn dữ liệu vô cùng quý giá phản ánh đúng điều kiện ánh sáng, góc chụp và các biến thể hình thái thực tế của bệnh hại.

Hệ thống được định hướng lưu trữ các ảnh dự đoán này vào cơ sở dữ liệu. Định kỳ hoặc khi số lượng ảnh đạt một ngưỡng nhất định, quản trị viên có thể kích hoạt tiến trình kiểm duyệt, gán nhãn chính xác từ phản hồi của nhà vườn và đưa vào tập dữ liệu huấn luyện bổ sung. Bằng phương pháp Transfer Learning, mô hình MobileNetV2 sẽ được tái huấn luyện trên tập dữ liệu mở rộng này mà không cần huấn luyện lại từ đầu.

Hướng đi này hoàn toàn tương đồng với định hướng nghiên cứu của Trương Thị Phương Thanh và Nguyễn Thái Nghe (2021) khi ứng dụng phương pháp học chuyển giao để nhận dạng bệnh trên lá lúa, đã nhấn mạnh giải pháp mở rộng ứng dụng với tính năng tự động huấn luyện khi được bổ sung thêm hình ảnh thực tế [12]. Cơ chế này giúp hệ thống

của đề tài liên tục tối ưu hóa theo thời gian, cập nhật kịp thời các biến thể mới của bệnh trên cây có múi ngoài thực địa mà không làm tiêu tốn quá nhiều tài nguyên hay thời gian tính toán của máy chủ.

4.5.2. Tích hợp đa tiêu chí lâm sàng hỗ trợ dự đoán

Nhận diện qua hình ảnh đơn thuần đôi khi gặp giới hạn do hiện tượng các bệnh khác nhau nhưng biểu hiện tổn thương tương tự nhau, ví dụ: bệnh vàng lá gân xanh và thiếu dinh dưỡng (thiếu vi lượng). Để khắc phục điểm yếu này, hệ thống thảo luận hướng phát triển cho phép chủ vườn nhập thêm các tiêu chí phụ trợ như: độ tuổi của cây, vị trí xuất hiện triệu chứng (lá non hay lá già), tình trạng phân bón gần nhất hoặc độ ẩm đất...

Phương pháp này có nét tương đồng với giải pháp hệ thống của Doan và Huynh (2017) [16]. Trong nghiên cứu, tác giả đã chứng minh hiệu quả vượt trội khi kết hợp các yếu tố ngữ cảnh môi trường (như điều kiện khí hậu thực tế) vào mô hình tính toán để tối ưu hóa năng lực dự đoán tổn thất dịch bệnh hại cây trồng. Bằng cách xử lý kết hợp kết quả trích xuất đặc trưng từ mô hình thị giác máy tính (Computer Vision) cùng các dữ liệu ngữ cảnh này thông qua một mạng nơ-ron đa phương thức, hệ thống trong tương lai sẽ đưa ra kết luận chẩn đoán cuối cùng với độ tin cậy vượt trội, giảm thiểu tối đa tỷ lệ báo động giả giữa các nhóm bệnh có biểu hiện tương đồng ngoài nhà vườn.

4.5.3. Khai phá nhật ký bệnh trạng để dự báo theo dòng thời gian

Hệ thống quản lý hiện tại đã xây dựng được phân hệ Nhật ký bệnh, ghi nhận mốc thời gian và tình trạng dịch bệnh. Khi lượng dữ liệu lịch sử này đủ lớn (qua nhiều mùa vụ), hệ thống có khả năng áp dụng các thuật toán khai phá dữ liệu dòng thời gian (Time-series Analysis) hoặc mô hình dự báo chuỗi thời gian như LSTM/ARIMA để dự báo bệnh.

Ý tưởng dịch chuyển từ "nhận diện" sang "dự báo nguy cơ" này đã được thực thi thực tế và chứng minh tính khả thi cao trong nghiên cứu của Doan và Huynh (2017), khi dự báo mức độ thiệt hại của bệnh dịch trong các tuần tiếp theo dựa trên việc phân tích chuỗi dữ liệu lịch sử bệnh trạng trước đó kết hợp cùng thuật toán tối ưu [16]. Áp dụng vào đề tài cây có múi, dữ liệu tích lũy từ nhật ký bệnh trạng sẽ trở thành kho tài nguyên quý giá để dự báo sớm xu hướng bùng phát của một số loại bệnh cụ thể theo tháng hoặc theo chu kỳ thời tiết đặc trưng (ví dụ: dự báo đỉnh điểm bùng phát của bệnh ghẻ loét vào các tháng mùa

mưa có độ ẩm cao). Việc chủ động phát hiện nguy cơ dịch bệnh theo mùa sẽ nâng tầm hệ thống thành một nền tảng số hóa nông nghiệp toàn diện, hỗ trợ người nông dân và ban quản lý Hợp tác xã tối ưu hóa lịch trình phun thuốc bảo vệ thực vật, chủ động khoanh vùng dập dịch và giảm thiểu tối đa tổn thất kinh tế.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Trong khuôn khổ đề tài “Xây dựng hệ thống quản lý vườn cây và hỗ trợ dự đoán một số bệnh trên cây có múi”, nghiên cứu đã hoàn thành việc khảo sát, thiết kế và triển khai một hệ thống công nghệ toàn diện, có sự tích hợp chặt chẽ giữa giao diện web, hệ thống quản trị Backend và module học máy chuyên sâu nhằm hỗ trợ quản lý canh tác cũng như phát hiện dịch bệnh từ ảnh lá hoặc quả từ thực địa.

Thông qua quá trình thực hiện, đề tài đã đạt được một số kết quả cốt lõi. Trước hết, hệ thống quản lý canh tác đã được xây dựng hoàn chỉnh với đầy đủ các chức năng phân quyền quản lý vườn cây, chia nhỏ phân vùng sản xuất (plot), ghi nhật ký canh tác liên kết và lưu trữ thông tin bệnh lý, cho phép ban quản lý cùng người nông dân theo dõi lịch sử sản xuất một cách có hệ thống và khoa học. Đối với phân hệ dự đoán bệnh, đề tài đã triển khai thành công huấn luyện sử dụng kỹ thuật học chuyển giao trên kiến trúc mạng MobileNetV2, kết hợp các phương pháp tiền xử lý dữ liệu ảnh và phân chia tập thực nghiệm theo tỷ lệ tối ưu 80/10/10. Mô hình sau huấn luyện đạt được độ chính xác cùng các chỉ số đánh giá kỹ thuật ở mức tốt, đảm bảo độ tin cậy để ứng dụng làm một công cụ đắc lực hỗ trợ ra quyết định bảo vệ mùa màng.

Bên cạnh đó, tính minh bạch và khả năng giải thích của mô hình đã được giải quyết bằng việc tích hợp kỹ thuật trực quan hóa Grad-CAM vào quá trình suy luận (inference), cung cấp bản đồ chú ý thị giác (heatmap) thể hiện rõ ràng vùng ảnh mà mô hình dựa vào để đưa ra dự đoán. Cuối cùng, về mặt triển khai, luồng kết nối đa tầng giữa Frontend, Backend và mô hình ML đã được tối ưu hóa đồng bộ, cung cấp các giao tiếp API dự đoán thời gian thực giúp hiển thị kết quả chẩn đoán và hình ảnh Grad-CAM trực quan ngay trên giao diện Web.

Mặc dù chứng minh được tính khả thi cao trong việc ứng dụng trí tuệ nhân tạo vào thực tiễn nông nghiệp, đề tài vẫn tồn tại một số hạn chế nhất định cần ghi nhận. Nguồn dữ liệu hình ảnh hiện tại chưa đạt độ đa dạng lý tưởng để bao quát mọi điều kiện thời tiết ngoài thực tế; một vài lớp bệnh còn khan hiếm mẫu vật dễ dẫn đến hiện tượng nhận diện nhầm lẫn, đồng thời hiệu năng suy luận chưa được tối ưu hóa hoàn toàn cho các thiết bị có cấu hình phần cứng hạn chế như di động. Tuy nhiên, nhìn một cách tổng thể, đề tài đã giải

quyết trọn vẹn các mục tiêu đặt ra và mở ra một hướng tiếp cận số hóa nông nghiệp thực chất, hiệu quả.

5.2. Hướng phát triển

Dựa trên những kết quả đã đạt được cùng các hạn chế còn tồn tại, đề tài đề xuất các hướng nghiên cứu và phát triển tiếp theo nhằm tối ưu hóa hệ thống trong tương lai. Hướng đi tiên quyết là mở rộng quy mô và nâng cao chất lượng hóa dữ liệu thông qua việc thu thập thêm mẫu ảnh từ nhiều vùng địa lý, đa dạng hóa điều kiện ánh sáng và góc chụp, đồng thời tập trung tăng cường số lượng mẫu cho các lớp dịch bệnh khan hiếm, đảm bảo quy trình gán nhãn chính xác dưới sự tham vấn của các chuyên gia bảo vệ thực vật. Song song đó, việc nâng cấp mô hình và tối ưu hóa quy trình huấn luyện sẽ được thực hiện bằng cách thử nghiệm các kiến trúc mạng hiện đại hơn như EfficientNet hay Vision Transformer, kết hợp áp dụng kỹ thuật tinh chỉnh chuyên sâu, tối ưu hóa tham số và sử dụng các phương pháp học máy tổ hợp nhằm gia tăng độ ổn định.

Một hướng phát triển mang tính đột phá khác là tích hợp dữ liệu đa nguồn (multimodal data). Bằng cách kết hợp thông tin hình ảnh lâm sàng với các dữ liệu như điều kiện thời tiết, độ ẩm khí quyển, độ pH của đất và lịch trình bón phân, mô hình sẽ nâng cao đáng kể năng lực phân biệt các ca bệnh phức tạp có triệu chứng tương đồng. Để đưa ứng dụng đến gần hơn với người nông dân, việc tối ưu hóa mô hình thông qua các kỹ thuật Model Quantization và Network Pruning sẽ được triển khai, phục vụ mục đích phát triển các ứng dụng di động độc lập chạy mượt mà trên hai hệ điều hành Android và iOS ngay cả trong điều kiện không có mạng Internet.

Cuối cùng, hệ thống hướng tới việc xây dựng các cảnh báo thông minh, chủ động gợi ý các biện pháp can thiệp sinh học hoặc hóa học và kết nối trực tiếp với lịch canh tác để tối đa hóa hiệu quả quản lý của Hợp tác xã. Khi quy trình công nghệ đã được hoàn thiện và tối ưu hóa, hệ thống hoàn toàn có thể mở rộng phạm vi áp dụng sang các loại cây trồng có giá trị kinh tế mũi nhọn khác của địa phương như lúa, cà phê hay hồ tiêu bằng cách thu thập các bộ dữ liệu chuyên biệt và tinh chỉnh lại mô hình cho phù hợp.

PHỤ LỤC

1. Phân bố dữ liệu theo lớp bệnh

Tập dữ liệu sử dụng trong nghiên cứu bao gồm **13.202** ảnh lá và quả của cây cam, được phân thành 10 lớp bệnh như sau:

Lớp bệnh	Số lượng ảnh	Tỷ lệ (%)
Bệnh đốm đen	806	6.11%
Bệnh loét	2713	20.55%
Thiếu dinh dưỡng	2004	15.18%
Bệnh đốm dầu	173	1.31%
Vàng lá gân xanh	1039	7.87%
Cây khỏe mạnh	3157	23.91%
Sâu vẽ bùa	828	6.27%
Bệnh hỗn hợp	750	5.68%
Sâu ăn lá	1098	8.32%
Xoăn lá	634	4.80%
Tổng cộng:	13202	100%

2. Nguồn dữ liệu

Dữ liệu được tổng hợp từ nhiều nguồn khác nhau:

- Kaggle Citrus Leaf Disease Dataset
- Orange Leaf Disease Dataset
- Suriname Citrus Dataset
- Orange diseases dataset
- Plant Disease dataset
- Một số nguồn trên Internet khác

Việc kết hợp nhiều nguồn giúp tăng tính đa dạng và khả năng tổng quát của mô hình.

3. Chia tập dữ liệu

Dữ liệu được chia theo tỷ lệ:

- Tập huấn luyện: 80%
- Tập xác thực: 10%
- Tập kiểm tra: 10%

4. Cấu hình mô hình

Mô hình sử dụng kiến trúc MobileNetV2 với các tham số:

- Input: 224×224
- Output: 10 lớp
- Activation: Softmax
- Loss: Categorical Crossentropy
- Optimizer: Adam
- Batch size: 32
- Epochs: 10

5. Kết quả tổng thể

- Accuracy (Train): 92.46%
- Accuracy (Validation): 94.85%
- Loss (Train): 0.2124
- Loss (Validation): 0.1496

6. Kết quả trên tập kiểm tra

Chỉ số	Weighted	Macro
Accuracy	94.86%	-
Precision	95.24%	92.39%
Recall	94.86%	92.76%
F1-Score	94.94%	92.41%

7. Kết quả từng loại bệnh

Lớp	Precision	Recall	F1-Score	Số mẫu
Bệnh đốm đen	0.93	0.91	0.92	81
Bệnh loét	0.99	0.97	0.98	271
Bệnh xoắn lá	0.98	0.83	0.90	63
Thiếu dinh dưỡng	0.98	0.98	0.98	200
Bệnh đốm nâu	0.87	0.76	0.81	17
Bệnh vàng lá gân xanh	0.75	0.91	0.83	104
Cây khỏe mạnh	0.98	0.94	0.96	316
Sâu ăn lá	0.86	0.98	0.92	110
Sâu vẽ bùa	1.00	0.93	0.96	83
Bệnh hỗn hợp	1.00	0.99	0.99	75
Macro Average	0.93	0.92	0.93	1320
Weighted Average	0.95	0.95	0.95	1320

8. Quy trình

1. Upload ảnh mới
2. Gộp dữ liệu
3. Tiền xử lý và tăng cường; chia lại dataset (train/val/test)
4. Huấn luyện lại model
5. Lưu model nếu tốt hơn

DANH MỤC TÀI LIỆU THAM KHẢO

Tiếng Việt

1. AgriDrone Việt Nam (không rõ năm), “Cây cam bị xoắn lá: Nguyên nhân và cách phòng trừ”, Trang web: <https://agridrone.vn/cay-cam-bi-xoan-la/>, truy cập ngày 24/04/2026.
2. Dự án WB7 (2021), “Sổ tay Hướng dẫn sử dụng thuốc bảo vệ thực vật trên cây có múi (Hòa Bình)”, Ban quản lý các dự án Nông nghiệp (CPO), Trang web: [http://cpo.vn/Uploads/2021/3/6/15/s%E1%BB%95%20tay%20H%C6%B0%E1%BB%9Bng%20d%E1%BA%ABn%20s%E1%BB%AD%20d%E1%BB%A5ng%20th%E1%BB%91c%20BVTV%20tr%C3%AA%20c%C3%A2y%20c%C3%B3%20m%C3%BAi%20\(H%C3%B2a%20B%C3%ACnh\).pdf](http://cpo.vn/Uploads/2021/3/6/15/s%E1%BB%95%20tay%20H%C6%B0%E1%BB%9Bng%20d%E1%BA%ABn%20s%E1%BB%AD%20d%E1%BB%A5ng%20th%E1%BB%91c%20BVTV%20tr%C3%AA%20c%C3%A2y%20c%C3%B3%20m%C3%BAi%20(H%C3%B2a%20B%C3%ACnh).pdf), truy cập ngày 24/04/2026.
3. Đức Thành Agri (không rõ năm), “Bệnh đốm đen trên cây cam và biện pháp phòng trừ hiệu quả”, Công ty TNHH Đức Thành, Trang web: <https://ducthanhagri.com/benh-dom-den-tren-cay-cam/>, truy cập ngày 24/04/2026.
4. FPT Smart Cloud (2023), Kỹ thuật Transfer Learning trong huấn luyện mô hình, FPT.AI, Trang web: <https://fpt.ai/vi/bai-viet/transfer-learning/>, truy cập ngày 24/04/2026.
5. Nguyễn Đình Hiếu (2020), CNN Architecture Series #1: MobileNets - Mô hình gọn nhẹ cho Mobile Applications, Viblo, Trang web: <https://viblo.asia/p/cnn-architecture-series-1-mobilenets-mo-hinh-gon-nhe-cho-mobile-applications-1VgZvJV1ZAw>, truy cập ngày 24/04/2026.
6. Kim Nông Goldstar (không rõ năm), “Hiện tượng thiếu dinh dưỡng cây trồng trên cam quýt và cách khắc phục”, Trang web: <https://kimnonggoldstar.vn/thieu-dinh-duong-cay-trong-tren-cam-quyt-va-cach-khac-phuc/>, truy cập ngày 24/04/2026. (Sử dụng cho mục: Thiếu dinh dưỡng).
7. Kozo Communications (2024), Quy trình làm việc của Machine Learning, Trang web: <https://kozocom.vn/machine-learning/>, truy cập ngày 24/04/2026.

8. Nguyễn Văn Nga, Cao Văn Chí (không rõ năm), “Tài liệu kỹ thuật trồng và chăm sóc cây có múi”, Bộ Nông nghiệp và Phát triển nông thôn, Trang web: <https://online.fliphtml5.com/pxbi/bvfx/#p=1>, truy cập ngày 24/04/2026.
9. Nông Nghiệp Phô (không rõ năm), “Cách trị sâu ăn lá hiệu quả và an toàn cho cây trồng”, Trang web: <https://nongnghieppho.vn/blogs/news/cach-tri-sau-an-la>, truy cập ngày 24/04/2026.
10. Vũ Khắc Nhượng (2014), “Sâu bệnh hại cây có múi và biện pháp phòng trừ”, Nhà xuất bản Nông nghiệp, Trang web: https://khuyennongvn.gov.vn/portals/0/tailieu/2014/12/host/sau_benh_cay_co_mui.pdf, truy cập ngày 24/04/2026.
11. Nguyễn Hồng Quyền, Trần Văn Tuấn, Lê Hoàng Việt (2020), “Nhận diện tự động một số chủng loại bệnh hại phổ biến trên cây cam tại khu vực Đồng bằng sông Cửu Long bằng mạng nơ-ron tích chập”, Tạp chí Khoa học và Công nghệ Nông nghiệp Việt Nam, số 4, tr. 45–52.
12. Trương Thị Phương Thanh, Nguyễn Thái Nghe (2021), “Nhận dạng bệnh trên lá lúa bằng phương pháp học chuyển giao”, Tạp chí Khoa học Trường Đại học Cần Thơ, Tập 57, Số 4, tr. 11-19. Trang web: <https://ctujsvn.ctu.edu.vn/index.php/ctujsvn/article/view/4192/4217>
13. TopDev (2026), “MongoDB là gì? Định nghĩa đầy đủ và chi tiết nhất về MongoDB”, TopDev Blog, Đường dẫn truy cập: <https://topdev.vn/blog/mongodb-la-gi/>, truy cập ngày 24/04/2026.

Tiếng Anh

14. Bray, T. (2017), The JavaScript Object Notation (JSON) Data Interchange Format, RFC 8259, Internet Engineering Task Force (IETF).
15. Chinchor, N. (1992), "MUC-4 evaluation metrics", Proceedings of the 4th Message Understanding Conference, pp. 22–29.

16. Doan, T. N., & Huynh, P. H. (2017), "A novel system for predicting the damage of rice diseases in An Giang province, Vietnam", Journal of Tra Vinh University, Vol 1, No 25, pp. 41-47. Trang web: <https://journal.tvu.edu.vn/index.php/journal/article/view/41/35>
17. Fawcett, T. (2006), "An introduction to ROC analysis", Pattern Recognition Letters, 27(8), pp. 861–874.
18. Ferentinos K. (2018), Deep learning models for plant disease detection and diagnosis, *Computers and Electronics in Agriculture*, 145, pp. 311–318.
19. Fielding, R. (2000), Architectural Styles and the Design of Network-based Software Architectures, Doctoral dissertation, University of California, Irvine.
20. Fielding, R. T., Taylor, R. N. (2002), "Principled design of the modern Web architecture", ACM Transactions on Internet Technology (TOIT), 2(2), pp. 115-150.
21. Goodfellow I., Bengio Y., Courville A. (2016), *Deep Learning*, MIT Press.
22. Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., Adam, H. (2017), MobileNets: Efficient convolutional neural networks for mobile vision applications, arXiv preprint arXiv:1704.04861.
23. Hughes, D. P., Salathé, M. (2015), An open access repository of images on plant health to enable the development of mobile disease diagnostics, arXiv preprint arXiv:1511.08065.
24. Kamilaris, A., Prenafeta-Boldú, F. X. (2018), Deep learning in agriculture: A survey, *Computers and Electronics in Agriculture*, 147, pp. 70–90.
25. Kurose, J. F., Ross, K. W. (2021), Computer Networking: A Top-Down Approach, 8th Edition, Pearson.
26. Meta Platforms (2026), *React*, Trang web: <https://react.dev/>, truy cập ngày 24/04/2026.

27. OpenJS Foundation (2024), *Express.js*, Trang web: <https://expressjs.com/>, truy cập ngày 24/04/2026.
28. OpenJS Foundation (2026), *Node.js*, Trang web: <https://nodejs.org/>, truy cập ngày 24/04/2026.
29. Pan, S. J., Yang, Q. (2010), A survey on transfer learning, *IEEE Transactions on Knowledge and Data Engineering*, 22, pp. 1345–1359.
30. Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., Chen, L. C. (2018), MobileNetV2: Inverted Residuals and Linear Bottlenecks, *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.
31. Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., Batra, D. (2017), Grad-CAM: Visual explanations from deep networks via gradient-based localization, *IEEE International Conference on Computer Vision (ICCV)*.
32. Sladojevic, S., Arsenovic, M., Anderla, A., Culibrk, D., Stefanovic, D. (2016), Deep neural networks based recognition of plant diseases by leaf image classification, *Computational Intelligence and Neuroscience*.
33. Sokolova, M., Lapalme, G. (2009), "A systematic analysis of performance measures for classification tasks", *Information Processing & Management*, 45(4), pp. 427–437.